

XML

Validation des documents XML

Échange des données dans l'entreprise

- Les échanges de données dans l'entreprise sont divers.
- Ils peuvent être liés
 - **aux infrastructures** (réseaux, machines, automates, bases de données, logiciels...),
 - **aux métiers** (échange entre personnes, échange entre services...),
 - **aux intervenants externes** (délocalisation, fournisseurs...).
- Bref, toutes ces circulations de données participent au bon fonctionnement de l'entreprise.

Erreurs dans l'échange des données

- Certaines données sont liées à une opération manuelle et d'autres à une opération automatique.
- Dans les deux cas, des erreurs sont toujours possibles,
 - soit par une erreur de saisie,
 - soit par une erreur de programmation.

Rôle de la validation dans l'entreprise

- Dans un processus de développement du logiciel, les fluctuations des demandes client et les évolutions des programmes rendent indispensable la validation.
- La validation peut toujours servir lors du développement à **contrôler que les données XML sont correctement structurées.**

Rôle de la validation dans l'entreprise

- La validation va **renforcer la qualité des échanges** en contraignant l'émetteur de données et le consommateur de données à vérifier la cohérence des données structurées en XML.
- La validation revient à **établir un visa sur le document XML**.

Outils de validation

- La plupart des outils XML, et notamment les parseurs XML, Permettent la validation de documents XML.
- Les parseurs courants supportent une ou plusieurs formes de grammaires.
 - Les **DTD** (*Document Type Definition*) sont la forme la plus ancienne et sont présentes dans la plupart des outils.
 - Ensuite les **schémas XML** (du W3C), une forme de grammaire plus moderne mais également plus complexe.
 - Enfin, il existe **d'autres alternatives (XDR, XSD, ...)**.

DTD

1. Syntaxe DTD

DTD (Document Type Definition)

- Une DTD *est une forme de grammaire relativement ancienne* car issue de l'univers SGML.
- Une DTD peut être interne ou externe au document XML.
- L'usage voudra que l'on privilégie la forme externe pour des raisons de maintenance et de facilité d'accès.

DTD interne

- Déclaration

<!DOCTYPE elt-racine **déclarations**>

Exemple

```
<?xml version="1.0" standalone="yes"?>
  <!DOCTYPE parent [
    <!ELEMENT parent (garcon, fille)>
    <!ELEMENT garcon (#PCDATA)>
    <!ELEMENT fille (#PCDATA)>
  ]>
  <parent>
    <garcon>Mamadou</garcon>
    <fille>Marième</fille>
  </parent>
```

DTD externe :

- Le fichier **parent.dtd**

```
<!ELEMENT parent (garcon, fille)>
```

```
<!ELEMENT garcon (#PCDATA)>
```

```
<!ELEMENT fille (#PCDATA)>
```

Le fichier **parent.xml**

```
<?xml version="1.0" standalone="no"?>
```

```
<!DOCTYPE parent SYSTEM  
"parent.dtd">
```

```
<parent>
```

```
  <garcon>Mamadou</garcon>
```

```
  <fille>Marième</fille>
```

```
</parent>
```

La définition d'un élément

- L'élément (ou balise) est exprimé par l'instruction **ELEMENT** suivie du nom de l'élément que l'on souhaite décrire et de son contenu.
- Ce dernier n'englobe que les éléments situés directement sous cet élément (les éléments fils).
- Voici une synthèse de cette syntaxe :
 - `<!ELEMENT unNom DEF_CONTENU>`

La définition d'un élément

- La définition d'un élément peut contenir :
 - **EMPTY** : l'élément n'a pas de contenu.
 - **ANY** : l'élément peut contenir n'importe quel élément présent dans la DTD.
 - **(#PCDATA)** : l'élément contient du texte.
 - **Un élément ou un ensemble d'éléments** placé entre parenthèses.
 - Un ensemble d'éléments peut avoir comme **séparateur**
 - Opérateur de choix (|)
 - Opérateur de suite (,)

Exemple: opérateur de choix

<!ELEMENT personne (nom_prenom | nom)>

<!ELEMENT nom_prenom (#PCDATA)>

<!ELEMENT nom (#PCDATA)>

Cela nous autorise deux documents soit :

```
<personne>
```

```
  <nom_prenom>Ibrahima FALL</nom_prenom>
```

```
</personne>
```

ou bien :

```
<personne>
```

```
  <nom>FALL</nom>
```

```
</personne>
```

Exemple: opérateur de séquence

<!ELEMENT personne(prenom,nom)>

<!ELEMENT prenom (#PCDATA)>

<!ELEMENT nom (#PCDATA)>

- Ici, l'opérateur de séquence limite les possibilités à un seul document XML valide :

<personne>

 <prenom>Ibrahima</prenom>

 <nom>FALL</nom>

</personne>

La définition d'un élément

- Les contenus (élément ou groupe d'éléments) peuvent être quantifiés par les opérateurs $*$, $+$ et $?$.
- Ces opérateurs sont liés au concept de cardinalité.
- Lorsqu'il n'y a pas d'opérateur, la quantification est de 1 .

La définition d'un élément

- Voici le détail de ces opérateurs :
 - * : 0 à n fois ;
 - + : 1 à n fois ;
 - ? : 0 ou 1 fois.
- Quelques exemples :
 - <!ELEMENT plan (introduction?,chapitre+,conclusion?)>
 - <!ELEMENT chapitre (auteur*,paragraphe+)>
 - <!ELEMENT livre (auteur?,chapitre)+>

La définition d'un élément

Notations

(a, b) séquence

(a|b) liste de choix

a? élément optionnel [0,1]

a* élément répétitif [0,N]

a+ élément répétitif [1,N]

Exemples

(nom, prenom, rue, ville)

(oui|non)

(nom, prenom?, rue, ville)

(produit*, client)

(produit*, vendeur+)

La définition d'un attribut

- Les attributs sont précisés dans l'instruction ATTLIST.
- indépendante de l'instruction ELEMENT
- on précise à nouveau le nom de l'élément sur lequel s'applique le ou les attributs.
- On peut considérer qu'il existe cette forme syntaxique :
 - nom TYPE OBLIGATION VALEUR_PAR_DEFAULT

Les TYPE d'attributs

- CDATA : du texte (*Character Data*) ;
- ID : un identifiant unique;
- IDREF : une référence vers un ID ;
- IDREFS : une liste de références vers des ID;
- NMTOKEN : un mot ;
- NMTOKENS : une liste de mots;
- Une énumération de valeurs : chaque valeur est séparée par le caractère |.

OBLIGATION et VALEUR_PAR_DEFAULT

- L'OBLIGATION ne concerne pas les énumérations qui sont suivies d'une valeur par défaut.
- Dans les autres cas, on l'exprime ainsi :
 - #REQUIRED : attribut obligatoire.
 - #IMPLIED : attribut optionnel.
 - #FIXED : attribut avec une valeur.
- La VALEUR_PAR_DEFAULT est présente pour l'énumération ou lorsque la valeur est typée avec #IMPLIED ou #FIXED.

Quelques exemples :

- `<!ATTLIST chapitre`
titre **CDATA #REQUIRED**
auteur **CDATA #IMPLIED**`>`
 - L'élément chapitre possède ici un attribut titre obligatoire et un attribut auteur optionnel.
- `<!ATTLIST crayon`
couleur (**rouge | vert | bleu**) **"bleu"**`>`
 - L'élément crayon possède un attribut couleur dont les valeurs font partie de l'ensemble rouge, vert, bleu.

DTD - Exemple

annuaire.dtd

```
<!ELEMENT annuaire (personne*)>
<!ELEMENT personne (nom,prenom,email+)>
<!ATTLIST personne type (étudiant | professeur |
chanteur | musicien) "étudiant">
<!ELEMENT nom (#PCDATA)>
<!ELEMENT prenom (#PCDATA)>
<!ELEMENT email (#PCDATA)>
```

annuaire.xml

```
<?xml version="1.0" encoding="ISO-8859-1"?>
<!DOCTYPE annuaire SYSTEM "annuaire.dtd">
<annuaire>
  <personne type="étudiant">
    <nom>FALL</nom>
    <prenom>Mamadou</prenom>
    <email>mfall@gmail.com </email>
  </personne>
  <personne type="chanteur">
    <nom>DIOP</nom>
    <prenom>Moussa</prenom>
    <email>Mdiop@yahoo.fr</email>
  </personne>
</annuaire>
```

DTD - Exemple

contacts.dtd

```
<!ELEMENT contacts (personne+)>
<!ELEMENT personne (nom, prénom, dateDeNaissance?,
adresse, email+, téléphone*)>
<!ELEMENT nom (#PCDATA)>
<!ELEMENT prénom (#PCDATA)>
<!ELEMENT dateDeNaissance (#PCDATA)>
<!ELEMENT adresse EMPTY>
<!ELEMENT email (#PCDATA)>
<!ELEMENT téléphone (#PCDATA)>
<!ATTLIST adresse pays CDATA #REQUIRED>
```

contacts.xml

```
<contacts>
  <personne>
    <nom>Ndiaye</nom>
    <prénom>ibrahima</prénom>
    <dateDeNaissance>1981-07-09
  </dateDeNaissance>
    <adresse pays="Sénégal"/>
    <email>indiaye@voila.fr</email>
    <email>iboundiaye@hotmail.com</email>
    <téléphone>77 534 45 67</téléphone>
  </personne>
  <personne>
    <nom>Diatta</nom>
    <prénom>Joséphine</prénom>
    <dateDeNaissance>1977-01-06
  </dateDeNaissance>
    <adresse pays="Sénégal"/>
    <email>joediatta@voila.fr</email>
  </personne>
</contacts>
```


DTD

2. Liens croisés


Liens croisés

- Une entreprise fonctionne avec un **certain nombre de personnes** et gère un **certain nombre de projets**.
 - Une personne possède un nom et un ensemble d'informations personnelles qu'on ne détaillera pas.
 - Un projet est caractérisé par un nom et un descriptif.



Liens croisés

- Une **personne** peut participer à plusieurs projets et un **projet** peut être conduit par plusieurs personnes.



Identifiant unique (ID)

- Chaque *projet* et chaque *personne* devront être identifié(e)s par un attribut de type ID.
- `<!ELEMENT plan ( projet*, personne*)>`
- `<!ELEMENT projet (nom, description)>`
- `<!ATTLIST projet id_projet ID #REQUIRED>`
- `<!ELEMENT personne (nom, infos)>`
- `<!ATTLIST personne id_pers ID #REQUIRED>`

Référence vers un ID (IDREF)

- Chaque *projet* devrait avoir autant d'attributs de type IDREF, ayant pour valeur l'identifiant d'une personne, qu'il comprend de personnes.

```
<projet id_projet ="P005" id_membre=" M22 " id_membre=" M21 ">
```

...

```
</projet>
```

impossible

```
<projet id_projet ="P005 ">
```

```
  <membre id_membre="M22" />
```

```
  <membre id_membre="M21" />
```

...

```
</projet>
```

possible

Référence vers un ID (IDREF)

- <!ELEMENT plan (projet*, personne*)>
- <!ELEMENT projet (nom, description, membre*)>
- <!ATTLIST projet id_projet ID #REQUIRED>
- <!ELEMENT nom (#PCDATA)>
- <!ELEMENT description (#PCDATA)>
- <!ELEMENT membre EMPTY>
- <!ATTLIST membre id_membre IDREF #IMPLIED>

Référence vers un ID (IDREF)

- Chaque *personne* devrait avoir autant d'attributs de type IDREF ayant pour valeur l'identifiant d'un projet, qu'il y a de projets dont il est membre.
- Mais comme un élément ne peut pas avoir plusieurs attributs de même nom, il est nécessaire de définir un élément vide, participe, qui aura un attribut référençant un projet et pourra être présent plusieurs fois.

Référence vers un ID (IDREF)

- <!ELEMENT plan (projet*, **personne***)>
- <!ELEMENT personne (nom, infos, **participe***)>
- <!ATTLIST personne id_pers ID #REQUIRED>
- <!ELEMENT infos (#PCDATA) >
- <!ELEMENT **participe** EMPTY>
- <!ATTLIST **participe** **proj** IDREF #REQUIRED>

Exemple de document XML

```
<?xml version="1.0" encoding="UTF-8"?>
<!DOCTYPE plan SYSTEM "liens_croises_a.dtd">
<plan>
  <projet id_projet="p1">
    <nom>Traduction</nom>
    <description>description du projet Traduction</description>
    <membre id_membre="pers_01"/>
    <membre id_membre="pers_03"/>
  </projet>
  <projet id_projet="p2">
    <nom>Corpus</nom>
    <description>description du projet Corpus</description>
    <membre id_membre="pers_02"/>
    <membre id_membre="pers_03"/>
  </projet>
  <personne id_pers="pers_01">
    <nom>Jules</nom>
    <infos>informations sur Jules</infos>
    <participe proj="p1"/>
  </personne>
  <personne id_pers="pers_02">
    <nom>Luc</nom>
    <infos>informations sur Luc</infos>
    <participe proj="p2"/>
  </personne>
  <personne id_pers="pers_03">
    <nom>Marie</nom>
    <infos>informations sur Marie</infos>
    <participe proj="p1"/>
    <participe proj="p2"/>
  </personne>
</plan>
```


Liste de références vers des ID(IDREFS)

- On peut transposer directement le modèle précédent en remplaçant l'attribut de type IDREF des éléments membre et participe par un attribut de type IDREFS dont la valeur est une liste d'identifiants de *personnes* ou une liste d'identifiants de *projets*.
- De ce fait les éléments membre et participe n'ont plus à être multipliés et deviennent simplement facultatifs.

Liste de références vers des ID(IDREFS)

- <!ELEMENT plan (projet*, personne*)>
- <!ELEMENT projet (nom, description, membres?)>
- <!ATTLIST projet id_projet ID #REQUIRED>
- <!ELEMENT nom (#PCDATA)>
- <!ELEMENT description (#PCDATA)>
- <!ELEMENT membres EMPTY>
- <!ATTLIST membres les_pers IDREFS #IMPLIED>

Liste de références vers des ID(IDREFS)

- <!ELEMENT plan (projet*, **personne***)>
- <!ELEMENT personne (nom, infos, **participe?**)>
- <!ATTLIST personne id_pers ID #REQUIRED>
- <!ELEMENT infos (#PCDATA) >
- **<!ELEMENT participe EMPTY>**
- **<!ATTLIST participe les_proj IDREFS #IMPLIED>**

Liste de références vers des ID(IDREFS)

```
<?xml version="1.0" encoding="UTF-8"?>
<!DOCTYPE plan SYSTEM "liens_croises_b1.dtd">
<plan>
  <projet id_projet="p1">
    <nom>Traduction</nom>
    <description>description du projet Traduction</description>
    <membres les_pers="pers_01 pers_03"/>
  </projet>
  <projet id_projet="p2">
    <nom>Corpus</nom>
    <description>description du projet Corpus</description>
    <membres les_pers="pers_02 pers_03"/>
  </projet>
  <personne id_pers="pers_01">
    <nom>Jules</nom>
    <infos>informations sur Jules</infos>
    <participe les_proj="p1"/>
  </personne>
  <personne id_pers="pers_02">
    <nom>Luc</nom>
    <infos>informations sur Luc</infos>
    <participe les_proj="p2"/>
  </personne>
  <personne id_pers="pers_03">
    <nom>Marie</nom>
    <infos>informations sur Marie</infos>
    <participe les_proj="p1 p2"/>
  </personne>
</plan>
```

Liste de références vers des ID(IDREFS)

- L'utilisation des attributs de type IDREFS permet une solution plus simple.
- On peut en effet supprimer les éléments membre et participe et mettre directement les attributs les_pers et les_proj dans les éléments projet et personne.

Liste de références vers des ID(IDREFS)

- <!ELEMENT plan (**projet***, personne*)>
- <!ELEMENT projet (nom, description)>
- <!ATTLIST projet id_projet ID #REQUIRED
- les_pers IDREFS #REQUIRED>
-
- <!ELEMENT description (#PCDATA)>

Liste de références vers des ID(IDREFS)

- <!ELEMENT plan (projet*, **personne***)>
- <!ELEMENT personne (nom, infos)>
- <!ATTLIST personne id_pers ID #REQUIRED
les_proj IDREFS #IMPLIED>
- <!ELEMENT nom (#PCDATA)>
- <!ELEMENT infos (#PCDATA)>

Liste de références vers des ID(IDREFS)

```
<?xml version="1.0" encoding="UTF-8"?>
<!DOCTYPE plan SYSTEM "liens_croises_c.dtd">
<plan>
  <projet id_projet="p1" les_pers = "pers_01 pers_03">
    <nom>Traduction</nom>
    <description>description du projet Traduction</description>
  </projet>
  <projet id_projet="p2" les_pers = "pers_02 pers_03">
    <nom>Corpus</nom>
    <description>description du projet Corpus</description>
  </projet>
  <personne id_pers="pers_01" les_proj = "p1">
    <nom>Jules</nom>
    <infos>informations sur Jules</infos>
  </personne>
  <personne id_pers="pers_02" les_proj = "p2">
    <nom>Luc</nom>
    <infos>informations sur Luc</infos>
  </personne>
  <personne id_pers="pers_03" les_proj = "p1 p2">
    <nom>Marie</nom>
    <infos>informations sur Marie</infos>
  </personne>
</plan>
```