



UFR Sciences et Technologies
Département Informatique
M2 Génie Logiciel

* * *

2024-2025

BIG DATA

Pr Marie NDIAYE


Introduction au Big Data

Big Data

Le phénomène

C'est quoi le Big Data ?

- Le *Big Data* désigne **mégadonnées, grosses données** ou encore **données massives**.
- On parle de Big Data lorsque les outils classiques de gestion sont incapables de traiter convenablement les données produites.



<https://www.youtube.com/watch?v=an86433PT8Q>


Qu'est-ce qui a lancé le Big Data ?




Les appareils connectés

2021

- TikTok – 656 M
- Instagram - 545 M
- Facebook - 416 M
- WhatsApp - 395 M
- Snapchat - 327



Les réseaux sociaux




2023 : 11,7 zettaoctets (11,7 milliards de teraoctets) <-> x2 capacité en 2018

Les caractéristiques du Big Data

- **Les 3V**

- **Volume** – Un volume largement supérieur à ce que traitent les bases de données traditionnelles.
- **Vélocité** – Les données circulent vite entre les outils, les bases, les applicatifs, les sources. Les données sont traitées souvent en temps réel.
- **Variété** – les données sont dans leur majorité non-structurées ou semi-structurées.



Autres caractéristiques


- **Véracité** – Qualité des données.
- **Variabilité** – Variation de la qualité des données dans le temps.
- **Valeur** – Le défi ultime du Big Data est de créer de la valeur qui rappelle la finalité business de tout projet Big Data.
- **Visualisation** – Représentations (graphiques) complexes qui peuvent inclure de nombreuses variables de données tout en restant compréhensibles et lisibles.
- **Exemple** : données issues des réseaux sociaux, capteurs IoT, transactions, etc.

Big Data – Les solutions

- Le Big Dat est également défini comme « Une famille d'outils qui répondent à une triple problématique dite règle des 3V (Volume, Variété et Vélocité) : Ces outils s'adressent à la collecte, au stockage, au traitement, à l'analyse et à la restitution de données massives. »

Solutions – Systèmes de fichiers distribués

- Basés sur une architecture client/serveur dans laquelle le stockage de données sur des systèmes de stockage distribués est géré sur un serveur centralisé et rendu accessible aux clients via des protocoles de partage de fichiers. -> **Volume/Stockage**
 - Transparence de l'emplacement des fichiers.
 - Haute disponibilité et redondance des données.
 - Mobilité des données fondée sur des règles : possibilité de déplacer les données de manière transparente entre les différentes classes de stockage.
 - Possibilité d'évoluer à la demande (Scale Up, Scale out)



Solutions – Algorithmes distribués


- Principe : Les données sont envoyées aux agents, le calcul est effectué au niveau de ces agents et les résultats sont retournés au "coordonnateur"
 - Inverser la responsabilité (déplacer l'algorithme vers les données) afin de traiter de très grandes quantités de données -> **Volume/Traitement**
 - Réduire la dépendance entre les "agents" afin de maximiser le parallélisme
- Formalisation
 - Map/Reduce
 - Spark

Solutions – Bases de données NoSQL

- Non relationnelles : absence ou la flexibilité des schémas. Il n'est pas nécessaire de définir de schéma des données -> **Variété**
 - Les données de structures différentes peuvent être regroupées sur un même système.
 - Possibilité de stocker des données sous une forme non structurée
- Distribuées : de multiples bases NoSQL peuvent être exécutées de façon distribuée-> **Volume**
 - Capacités de mise à l'échel (*auto-scaling*)
 - Capacités de basculement (*fail-over*)

Solutions : Webscraping

- Technique permettant l'extraction des données d'un site via un programme, un logiciel automatique ou un autre site. -> **Volume/Vélocité**
- L'objectif est d'extraire le contenu d'une page d'un site de façon structurée.



Big Data vs Data Science vs Data Analytics : Description

Big Data	Analyse de données	Science des données
Fait référence à d'énormes volumes de données.	La science qui consiste à examiner les données brutes pour parvenir à certaines conclusions.	Traitant des données non structurées et structurées, la science des données est un domaine qui comprend tout ce qui est lié au nettoyage, à la préparation et à l'analyse des données.

Big Data vs Data Science vs Data Analytics : Objectif

Big Data	Analyse de données	Science des données
Comprend la capture, le stockage, le partage et l'interrogation des données.	Traiter et effectuer une analyse statistique des données. Découvrir comment les données peuvent être utilisées pour tirer des conclusions et résoudre des problèmes.	Extraire de grandes quantités de données structurées et non structurées pour identifier des modèles.

Big Data vs Data Science vs Data Analytics : Métier

Big Data	Analyse de données	Science des données
Big Data Professional – Analyser les goulots d'étranglement du système ; construire des systèmes de traitement de données à grande échelle ; architecte de systèmes distribués hautement évolutifs	Analyst – Acquérir, traiter et faire la synthèse des données ; regrouper les données pour obtenir des informations ;	Data Scientist – Prédire l'avenir sur la base des modèles passés ; explorer et examiner les données de plusieurs sources déconnectées ; développer de nouvelles méthodes analytiques et des modèles d'apprentissage automatique

Big Data vs Data Science vs Data Analytics : Applications

Big Data	Analyse de données	Science des données
Services financiers ; Communications ; vente au détail ; etc.	Santé ; Voyage ; Industrie Informatique; etc.	Moteurs de recherche ; services financiers ; E-commerce, etc.

Convergence Big Data – Data Science – IA

- **Big Data** : collecte et stockage massifs
- **Data Science** : exploration et analyse statistique
- **IA** : automatisation de l'apprentissage et de la décision
- **Complémentarité** : le Big Data alimente l'IA, l'IA valorise le Big Data.
- **Exemple** : modèles de recommandation Netflix, YouTube, Spotify.

Écosystème technologique du Big Data et de l'IA

- **Outils Big Data** : Hadoop, Spark, Kafka, NoSQL (MongoDB, Cassandra)
- **Outils IA** : TensorFlow, PyTorch, Scikit-learn
- **Langages** : Python, Scala, SQL
- **Infrastructures** : Cloud (AWS, Azure, Google Cloud)

Étude de cas d'application réelle

Santé : détection précoce de maladies à partir de données massives

Contexte et objectif

- **Contexte**

- Les établissements de santé collectent chaque jour d'immenses volumes de données :
 - dossiers médicaux électroniques (DME),
 - résultats de laboratoires,
 - imageries médicales,
 - données issues de capteurs et objets connectés (montres, tensiomètres, glucomètres),
 - publications scientifiques et essais cliniques.
- Le Big Data permet d'exploiter ces données pour anticiper les pathologies.

- **Objectif**

- Utiliser les données massives hétérogènes et non structurées pour détecter précocement des maladies chroniques ou infectieuses.

Méthodologie

- **Collecte et intégration des données**
 - Agrégation des DME, images médicales et données de capteurs en temps réel.
 - Utilisation de technologies Big Data : Hadoop, Spark, et bases NoSQL (MongoDB).
- **Nettoyage et normalisation**
 - Suppression des doublons, standardisation des formats, anonymisation pour la confidentialité.
- **Analyse prédictive via IA**
 - Application de modèles de Machine Learning (réseaux de neurones, forêts aléatoires).
 - Extraction de corrélations entre variables physiologiques et diagnostics précoces.
- **Visualisation et interprétation**
 - Outils de visualisation : Tableau, Power BI, ou Python (Matplotlib, Seaborn).
 - Tableaux de bord interactifs pour les médecins.

Exemple : Détection du diabète

- **Données** : glycémie, tension, indice de masse corporelle (IMC), antécédents familiaux.
- **Résultat** : Un modèle Big Data permettant de détecter des risques de diabète 6 mois avant les symptômes.
- **Outils** : Apache Spark + TensorFlow.
- **Impact** : réduction du taux de complications et meilleure orientation des patients vers la prévention.

Enjeux et bénéfices

- **Enjeux :**

- Protection des données de santé (RGPD, consentement).
- Biais possibles dans les modèles (jeu de données non représentatif).
- Besoin de compétences interdisciplinaires (médecine, data science, éthique).

- **Bénéfices :**

- Diagnostic plus rapide et précis.
- Réduction des coûts liés aux hospitalisations tardives.
- Amélioration du suivi personnalisé des patients.
- Contribution à la recherche médicale (découverte de nouveaux biomarqueurs).