



UFR Sciences et Technologies
Département Informatique
M2 Génie Logiciel

* * *

2024-2025

BIG DATA

Marie NDIAYE

MapReduce

HadoopMapReduce

MapReduce

- Jeffrey Dean and Sanjay Ghemawat, "Simplified Data Processing on Large Clusters", Google, 2004
- "MapReduce est un modèle de programmation et une implémentation associée pour le traitement et la génération de grands ensembles de données".
 - Permet de traiter de grosses volumes de données.
 - Repose sur la distribution des calculs sur des centaines ou des milliers d'ordinateurs pour finir dans un temps raisonnable.
 - Constitue une abstraction sur la manière de paralléliser les calculs, de distribuer les données, de traiter les pannes et de faire du load balancing
→ l'utilisateur se concentre sur les calculs.

Les primitives Map et Reduce

- Présentes dans le LISP et dans d'autres langages fonctionnels.
- Le principe :
 - L'utilisateur définit les fonctions Map et Reduce et le reste est géré par la bibliothèque MapReduce.
 - La **fonction Map**
 - Entrée : un couple (clé, valeur)
 - Sorties : un ensemble de couples (clé, valeur) intermédiaires
 - La **bibliothèque MapReduce**
 - Regroupe les couples ayant la même clé créant ainsi des couples (clé, liste de valeurs)
 - Passe les nouveaux couples à la fonction Reduce
 - La **fonction Reduce**
 - Entrée : un couple (clé, liste de valeurs)
 - Fusionne les valeurs pour obtenir un ensemble de valeurs éventuellement plus petit
 - Sortie : une liste de valeurs


Exemple

- Algorithme :
Compter le nombre d'occurrences de chaque mot dans un document.

```
map(String key, String value):  
    // key: document name  
    // value: document contents  
    for each word w in value:  
        EmitIntermediate(w, "1");
```

```
reduce(String key, Iterator values):  
    // key: a word  
    // values: a list of counts  
    int result = 0;  
    for each v in values:  
        result += ParseInt(v);  
    Emit(AsString(result));
```

Exemple : Exécution



Source : <https://www.talend.com/fr/resources/what-is-mapreduce/>

Implémentation de MapReduce dans Hadoop : Généralités

- Architecture maître-esclave.
- MapReduce s'intègre à HDFS pour offrir exactement les mêmes avantages pour le traitement parallèle des données.
- Envoie des calculs où les données sont stockées sur des disques locaux.
- Modèle ou framework de programmation pour le calcul distribué.
- Il dissimule les tâches complexes de "gestion domestique" au développeur que vous êtes.

Implémentation de MapReduce dans Hadoop : Le framework

- Le framework MapReduce se compose de :
 - Un processus **JobTracker** maître par cluster qui est chargé de planifier les tâches des composants des travaux sur les esclaves, de les surveiller et de réexécuter les tâches qui ont échoué. Il reçoit (du client) la ou les tâches MapReduce à exécuter(un .jar Java) ainsi que les données d'entrée et le répertoire où stocker les données de sortie. Il est pour cela en communication avec le namenode d'HDFS.
 - Un processus **TaskTracker** esclave par nœud de cluster qui exécute les tâches demandées par le maître.

Implémentation de MapReduce dans Hadoop : les fonctions

- **Map**

- Chaque tâche Map travaille généralement sur un seul bloc HDFS (répartition des entrées).-
- Les tâches Map s'exécutent sur les nœuds esclaves du cluster où le bloc de données HDFS est stocké (localité des données).
- L'entrée présentée à la tâche Map est une paire clé-valeur.


- **Shuffle and Sort**

- Trie et consolide les données de sortie intermédiaires de tous les mappeurs terminés de la phase Map.

- **Reduce**

- Les données intermédiaires de la phase Shuffle and Sort constituent l'entrée de la phase Reduce.
- La fonction Reduce génère la sortie finale.

Exemple : Comptage de mots



Références

- <https://www.thegeekdiary.com/understanding-the-hadoop-mapreduce-framework/>
- <https://www.geeksforgeeks.org/mapreduce-architecture/>
- <https://www.talend.com/fr/resources/what-is-mapreduce/>
- <https://www.piloter.org/business-intelligence/map-reduce.htm>
- <https://www.lebigdata.fr/mapreduce-tout-savoir>