



UFR Sciences et Technologies
Département Informatique
M2 Génie Logiciel

* * *

2024-2025

BIG DATA

Marie NDIAYE

SPARK


C'est quoi Spark ?

- Un framework open source de calcul distribué.
- Un ensemble d'outils et de composants logiciels structurés selon une architecture définie.
 - Développé à l'université de Californie à Berkeley par AMPLab3.
 - Actuellement un projet de la fondation **Apache**.
- Un cadre applicatif de traitements Big Data pour effectuer des analyses complexes à grande échelle.

Historique

- **2009**
 - Conçu par Matei Zaharia lors de son doctorat au sein de l'université de Californie à Berkeley.
- **2010**
 - Open source sous licence BSD (Berkeley Software Distribution License)
- **2013**
 - Transmis à la fondation Apache, Spark devient l'un des projets les plus actifs de cette dernière.
- **2014**
 - Gagnant du concours **Daytona GraySort Contest** dont l'objectif est de trier 100 To de données le plus rapidement possible. Ce record était préalablement détenu par Hadoop.

Daytona GraySort Contest



- Source : https://www.youtube.com/watch?v=RvvyugMS_1Q

Principe

- **Cible**

- Les applications qui utilisent un même ensemble de données dans plusieurs opérations en parallèles
 - Opérations itératives
 - Analyses interactives

- **Idée générale**

- Garder les données en mémoire du début à la fin de l'exécution des opérations.

Objectif : Gagner en performance en évitant de charger les données au début de chaque opération.

Généralités

- Repose sur
 - Un ensemble de données distribué résistant : **Resilient Distributed Dataset (RDD)** :
 - Collection d'objets
 - Accessibles uniquement en lecture
 - Partitionnés sur un ensemble de machines
 - L'utilisateur peut explicitement garder en mémoire un RDD dans les machines et le réutiliser dans de multiples opérations parallèles
 - Partition perdue restructurable
 - Des opérations en parallèle sur le RDD
 - Des variables globales
- Implémenté en Scala (langage OO fonctionnant avec la JVM)

Construction du RDD

- A partir d'un fichier stocké dans un système de fichiers distribué
- A partir d'une collection d'objets Scala : celle-ci est divisée en plusieurs parties qui sont ensuite envoyées à plusieurs nœuds
- A partir d'un RDD existant
 - Transformation des objets a l'aide de l'opération flatMap (Ex : transformer un itemset en un ensemble d'items).
 - Modification de la persistance d'un RDD : garder le RDD en mémoire après la première utilisation ou le sauvegarder dans un système de fichiers distribué.

S'il n'y a pas assez de mémoire dans le cluster pour mettre en cache toutes les partitions d'un ensemble de données, Spark les recalcule lorsqu'ils sont utilisés.

Exemple

- Compter le nombre de lignes contenant des erreurs

```
val file = spark.textFile("hdfs://...")  
val errs = file.filter(_.contains("ERROR"))  
val ones = errs.map(_ => 1)  
val count = ones.reduce(_+_)
```

- //Garder en mémoire un RDD

```
val cachedErrs = errs.cache()
```

spark.textFile : crée un jeu de données distribué **file** qui représente le fichier HDFS comme une collection de lignes.

filter : crée un nouvel ensemble de données à partir des lignes contenant la chaîne « ERROR »


map : mappe chaque ligne à 1

reduce : addition les 1

errs et **ones** sont des RDD non matérialisés (les partitions de données sont matérialisées à la demande) jusqu'à ce qu'on leur applique respectivement la fonction Map et la fonction Reduce.

Reconstruction des données

- Repose sur le **lignage**
 - Chaque objet contient
 - Un pointeur vers son parent ;
 - Des informations sur la façon dont le parent a été transformé.
 - Le lignage permet de reconstruire un jeu de données perdu ou de reprendre le travail en cas de panne dans une étape du workflow.



Variables partagées

- **Variable de diffusion**
 - Objet qui encapsule une valeur
 - Copiée une seule fois dans chaque worker
 - Lue par les workers dans plusieurs opérations parallèles
- **Accumulateur**
 - Modifiée par les workers par ajout
 - Lue par le programme pilote

Points forts et points faibles

- **Avantage**

- Rapidité
- Contributeurs : plus de 1 000 contributeurs dont plus de 200 sociétés différentes, comme **Intel, Facebook, IBM** et **Netflix**⁸.

- **Inconvénients**

- Limites du RDD
 - Mémoire rapidement épuisée si
 - Une opération génère beaucoup de données distinctes des données d'entrée (Exploration).
 - plusieurs séries d'opérations sont soumises de manière concurrente.
- Questions de coût sur Spark : Il incombe à l'utilisateur de faire un compromis entre
 - Le coût de stockage dans un RDD
 - La vitesse d'accès au RDD
 - La probabilité de perdre une partie du RDD
 - Le coût de recalculer le RDD
- Les variables de diffusion
 - Le temps de diffusion dépend du nombre de nœud
 - Risque de goulot d'étranglement si le contenu de la variable est volumineux
- Pas performant sur les algorithmes non récursifs


Utilisation

- ETL (par Talend, Hadoop...)
- Analyse prédictive et Machine Learning
- Opérations d'accès aux données (SQL)
- Traitement et extraction de texte
- Traitement en temps réel (streaming)
- Applications graphiques

Codage

- Spack est écrit en langage Scala et fonctionne avec la Java Virtual Machine.
- Il offre des API permettant de programmer dans différents langages :
 - Scala
 - Python
 - Java
 - SQL
 - R

Outils



- **Spark SQL**
 - Exécution de requêtes en langages SQL pour charger et transformer des données.
- **Spark Streaming**
 - Traitement des données en temps réel.
- **Spark Graph X**
 - Traitement d'informations issues de graphes.
- **Spark Mllib**
 - Bibliothèque d'apprentissage automatique :
 - Algorithmes et utilitaires d'apprentissage classiques, comme la classification, la régression, le clustering, le filtrage collaboratif et la réduction de dimensions.
 - Primitives d'optimisation sous-jacentes.

Références

- <https://www.data-transitionnumerique.com/comprendre-rdd-spark/>
- <https://openclassrooms.com/fr/courses/4297166-realisez-des-calculs-distribues-sur-des-donnees-massives/4308666-prenez-spark-en-main>
- <http://b3d.bdpedia.fr/spark-batch.html>
- http://www-bd.lip6.fr/wiki/_media/site/enseignement/master/bdle/p1_cours1_2016.pdf
- https://www.youtube.com/watch?v=RvvyugMS_lQ
- https://fr.wikipedia.org/wiki/Apache_Spark