

SYSTÈME DÉCISIONNEL

MASTER 2 INFORMATIQUE - GÉNIE LOGICIEL – 2018-2019



Marie NDIAYE |




ETL



RAPPEL

- Source : <http://perso.univ-lyon1.fr/haytham.elghazel/BI/presentation.html>



ETL

- **Extract** : extraction des données à partir du système de production et de sources externes ayant subi une modification depuis la dernière exécution.
 - Données structurés (BDR), semi-structurées (BD XML) et non structurées (documents, images, etc.)
- **Transform** : transformation des données pour les rendre homogènes (nettoyer, intégrer, formater, agréger, etc.)
 - Exemple : exprimer l'âge considérant l'année de naissance
- **Load** : chargement des données dans l'entrepôt et gestion des changements aux données existantes.
 - Régulier : journalier, hebdomadaire...
 - Incrémental (ajout de faits) ou recalculer les données (données agrégées)

CARACTÉRISTIQUES

- Permet la consolidation des données à l'aide des trois opérations suivantes d'**extraction, de transformation et de chargement**.
- Traite normalement de grande quantités de données en lots planifié;
- Est surtout utilisé avec les entrepôts de données et les datamarts.

AVANTAGES

- Optimisé pour la structure de l'entrepôt de données;
- Peut traiter de grandes quantités de données dans une même exécution (traitement en lot);
- Permet des transformations complexes et agrégations sur les données;
- La planification d'exécution peut être contrôlée par l'administrateur;
- La disponibilité d'outils GUI sur le marché permet d'améliorer la productivité;
- Permet la réutilisation des processus et transformations.

INCONVÉNIENTS

- Processus de développement long et coûteux;
- Gestion des changements nécessaire;
- Exige de l'espace disque pour effectuer les transformations (*staging area*);
- Exécuté indépendamment du besoin réel;
- Latence d'exécution important des données entre la source et l'entrepôt.

L'EXTRACTION DES DONNÉES

- Objectif : Extraire les données et les mettre dans un format commun
- choisir d'extraire ce qui est nécessaire :
 - Importer une partie des sources (pas la totalité)
 - Satisfaire les "vues utilisateurs"
- Appliquer une stratégie de rafraîchissement
 - Périodicité
 - Déclenchement

LES SOURCES I/2

- En général les "legacy systems" : bases de données de production
 - exemples : factures, fichier des nouveaux clients.
- On extrait les données pour ne pas travailler directement sur les sources
 - Incompatibilité entre décisionnel et transactionnel
 - perturbations
 - supports physiques différents
 - outils et utilisateurs différents

LES SOURCES 2/2

- Des sources extérieures :
 - météo
 - calendrier des jours fériés
 - cours de la bourse
 - Géographie (études épidémiologiques, accidents de la route)
 - études INSEE
- Vieilles sources

EXTRACTION DES DONNÉES I/3

- Que faire dans la pratique?
 - Identifier les sources de données et leurs structures;
 - Décider, pour chaque source, si l'extraction est faite à la main (ex: script) ou à l'aide d'un outil;
 - Choisir, pour chaque source, la fenêtre temporelle durant laquelle sera faite l'extraction;
 - Déterminer la séquence des tâches d'extraction;
 - Déterminer comment gérer les exceptions.

EXTRACTION DES DONNÉES 2/3

- Identification des sources
 1. Énumérer les items cibles (métriques et attributs de dimension) nécessaires à l'entrepôt de données;
 2. Pour chaque item cible, trouver la source et l'item correspondant de cette source;
 3. Si plusieurs sources sont trouvées, choisir la plus pertinente;
 4. Si l'item cible exige des données de plusieurs sources, former des règles de consolidation;
 5. Si l'item source referme plusieurs items cibles (ex: un seul champs pour le nom et l'adresse du client), définir des règles de découpage;
 6. Inspecter les sources pour des valeurs manquantes.

EXTRACTION DES DONNÉES 3/3

- Extraction complète :
 - Capture l'ensemble des données à un certain instant (*snapshot* de l'état opérationnel);
 - Normalement employée dans deux situations :
 1. Chargement initial des données;
 2. Rafraîchissement complet des données (ex: modification d'une source).
 - Peut être très coûteuse en temps (ex: plusieurs heures/jours).
- Extraction incrémentale :
 - Capture uniquement les données qui ont changées ou ont été ajoutées depuis la dernière extraction;
 - Peut être faite de deux façons :
 1. Extraction temps-réel;
 2. Extraction différée (en lot).

LES TECHNIQUES D'EXTRACTION

- Ecrire des interfaces entre les sources et l'entrepôt
- Exploiter les fonctionnalités de réplication offertes par les SGBD
 - loader, triggers, passerelles, copies, logs, vues, etc ...
- Utiliser un outil ETL
 - Génère les programmes d'alimentation
 - Peut gérer leur déroulement
 - Intégration de données



TRANSFORMATION DES DONNÉES

- Voir le cours 03 sur les données

CHARGEMENT DES DONNÉES

- **Chargement initial**
 - Fait une seule fois lors de l'activation de l'entrepôt de données;
 - Les indexes et contraintes d'intégrité référentielle (clé étrangères) sont normalement désactivés temporairement;
 - Peut prendre plusieurs heures.
- **Chargement incrémental**
 - Fait une fois le chargement initial complété;
 - Tient compte de la nature des changements (ex: SCD Type 1, 2 ou 3);
 - Peut être fait en temps-réel ou en lot.
- **Rafraîchissement complet**
 - Employé lorsque le nombre de changements rend le chargement incrémental trop complexe;
 - Ex: lorsque plus de 20% des enregistrements ont changé depuis le ndernier chargement.

APPLICATIONS POUR ETL

- Microsoft SQL Server Integration Services (SSIS)
- Oracle Warehouse Builder
- SAS Data Integration Studio
- IBM Infosphere Information Server
- Pentaho Data Integration
- Talend ETL Software
- RapidMiner

RÉFÉRENCE

- **MTI820 – Entrepôts de données et intelligence d'affaires**, Intégration des données et ETL,, S. Chafki, C. Desrosiers, Département de génie logiciel et des TI, ÉTS