

SYSTÈME DÉCISIONNEL

MASTER 2 GÉNIE LOGICIEL – 2018-2019



Marie NDIAYE |



LES DONNÉES

LES SOURCES I/2

- **En général les "legacy systems" : bases de données de production**
 - exemples : factures, fichier des nouveaux clients.
- **On extrait les données pour ne pas travailler directement sur les sources**
 - **Incompatibilité entre décisionnel et transactionnel**
 - perturbations
 - supports physiques différents
 - outils et utilisateurs différents

LES SOURCES 2/2

- Des sources extérieures :
 - météo,
 - calendrier des jours fériés,
 - cours de la bourse,
 - Géographie (études épidémiologiques, accidents de la route),
 - études INSEE.

- Vieilles sources

L'EXTRACTION DES DONNÉES

- Objectif : Extraire les données et les mettre dans un format commun
- choisir d'extraire ce qui est nécessaire :
 - Importer une partie des sources (pas la totalité)
 - Satisfaire les "vues utilisateurs"
- Appliquer une stratégie de rafraîchissement
 - Périodicité
 - Déclenchement

LES TECHNIQUES D'EXTRACTION

- Ecrire des interfaces entre les sources et l'entrepôt
- Exploiter les fonctionnalités de réplication offertes par les SGBD
 - loader, triggers, passerelles, copies, logs, vues, etc ...
- Utiliser un outil ETL
 - Génère les programmes d'alimentation
 - Peut gérer leur déroulement
 - Intégration de données

L'INTÉGRATION

- Intégration des données dans l'entrepôt en résolvant les conflits entre les différentes sources d'information
 - codages, fautes d'orthographe, etc...
 - tables de conversion, etc ...

ETUDIANTS	nom	sexe	adresse
	Figue	1	Paris
	Fraise	2	Toulouse

PROF	nom	sexe	adresse
	Figue	M	4, av. Foch Paris
	Fraise	F	4, av. Foch Paris

CAS À TRAITER 1/4

- Différence de codage:
 - sexe = M/F sexe = 1/2
- Différence d'unité
 - poids = 4000 poids = 4
 - taille = 38 taille = 7
- Différence de granularité
 - heures travaillées = 35 heures travaillées = 150
- Différence de fraîcheur :
 - âge = 20 âge = 21
- Imprécision
 - poids = 54,2 poids = 54
- Erreur :
 - nom = « Clémentine » nom = « Clémentinne »

CAS À TRAITER 2/4

- Différence de contenu dans les textes libres :
 - adresse = « Père Noël, cercle polaire, Rovaniemi, Finlande »
 - adresse = « cercle polaire, Rovaniemi, Finlande »

- Différence d'expression dans les textes libres :
 - adresse = « 4 av. du gal Leclerc »
 - adresse = « 4 avenue du général Leclerc »

- Différence linguistique de niveau de perception dans les textes libres :
 - couleur = « rouge »
 - couleur = « vermillon »

- prescription = « antibiotique »
- prescription = « pénicilline »

- Doublons

CAS A TRAITER 3/4

- Données manquantes
 - Fiches mal remplies.
 - Donnée non disponible
 - Pas de sens pour cet exemple
- Stratégies
 - Ignorer l'exemple
 - Ajouter une valeur
 - Remplacer par la valeur majoritaire (moyenne)
 - Remplacer par la valeur majoritaire (moyenne) chez les exemples de la même classe
 - Laisser
 - Trouver la 'meilleure' valeur par apprentissage

CAS À TRAITER 4/4

- Inconsistance
 - Un poids de 100kg pour une taille d'un mètre
 - Un pic montagneux au milieu d'une plaine
 - Un nombre de grossesses non nul pour un homme
 - Médicament déconseillé pour une pathologie
- Stratégies
 - Fixer des règles de cohérence
 - Dès le départ (expert du domaine)
 - Quand on a remarqué des valeurs 'louches'

EXERCICE I

■ Intégration?

Source 1

VOITURE	NUM	COULEUR
	1	AZUR
	2	VIOLET
	4	VERT

Source 2

VOITURE	NUM	COULEUR
	1	BLEU
	2	BLEU
	3	ROUGE
	4	VERT

EXERCICE 2

■ Intégration

ETUDIANT	NUM	NOM	SEXE	POIDS
	1	JEAN	1	54,2
	2	LAURA	2	65,6
	3	HENRI	1	48,4


Source 1

ETUDIANT	NUM	NOM	SEXE	POIDS
	1	JEAN	M	54
	2	LAURA	F	66
	3	HENRY	M	48
	4	FRED	M	70

Source 2


LES MÉTADONNÉES I/2

- Regroupent l'ensemble des informations concernant l'entrepôt et les processus associés.



LES MÉTADONNÉES 2/2

- Regroupent l'ensemble des informations concernant l'entrepôt et les processus associés.



LA TRANSFORMATION

- Lissage
- Regroupement d'attributs
- Généralisation, hiérarchisation : ville, région, pays
- Calcul de nouveaux attributs
- Normalisation

LA RÉDUCTION

- Réduire la complexité des données : réduire la complexité du calcul (temps, espace)
- Regrouper plusieurs attributs
- Supprimer les attributs sans intérêt
- Discrétiser les valeurs continues
- Echantillonner l'ensemble d'apprentissage (dans le cas spécifique de Data Mining)

L'ENRICHISSEMENT

- Ajouter des informations
 - Propres à chaque exemple.
 - Résultats de statistiques ou de fouilles précédentes
- Problèmes :
 - Formats des données
 - Cohérence avec les données connues
 - Unités
 - Actualité des données