

BIG DATA

Marie NDIAYE



UFR Sciences et Technologies
Département Informatique
M2 Génie Logiciel

* * *

2024-2025

Web scraping/ Web harvesting

- Un processus qui consiste à extraire des données de sites Internet et à les enregistrer afin de les analyser ou de les utiliser à d'autres fins.
- Il permet de collecter des informations de nature différente. Il peut par exemple s'agir de coordonnées comme des adresses e-mail ou des numéros de téléphone, mais aussi de mots-clés individuels ou d'URL.
- Ces informations sont alors rassemblées dans des bases de données locales ou des tableaux.

Le scraping manuel

- Il désigne le fait de copier et insérer manuellement des informations et des données.
- On peut le comparer avec le fait de découper et rassembler des articles de journaux.
- Il est uniquement effectué lorsque l'on souhaite trouver et enregistrer des informations de façon irrégulière.
- Il s'agit d'un processus très laborieux qui est rarement appliqué pour de grandes quantités de données.

Le scraping automatique

- Il utilise un logiciel (un algorithme ou un robot) qui explore une ou plusieurs pages web afin d'extraire du contenu.
- Exemple : Extraction des prix de divers produits spécifiques sur le site Amazon ou tout autre site d'e-commerce.

Méthodes de scraping automatique

- **Les analyseurs syntaxiques** utilisés pour convertir le texte en une nouvelle structure. Dans le cas de l'analyse d'un HTML par exemple, le logiciel lit le document HTML et enregistre les informations. L'analyse d'un DOM utilise l'affichage des contenus dans le navigateur côté client pour extraire les données.
- **Les robots** : un robot est un logiciel réalisant des tâches spécifiques et les automatisant. Dans le **Web harvesting**, les robots sont utilisés pour explorer automatiquement des sites Internet et collecter des données.
- **Le texte** : les personnes sachant utiliser la Command Line peuvent utiliser les instructions Unix grep pour explorer le Web à la recherche de certains termes dans Python ou Perl. Il s'agit d'une méthode très simple pour obtenir des données qui requiert toutefois davantage de travail que lorsqu'on utilise un logiciel.

Web Scraping vs Web Crawling

- Le web scraping est une question de données - les champs de données qu'on souhaite extraire de sites web spécifiques. Avec le scraping, on connaît généralement les sites web cibles, on ne connaît peut-être pas les URL des pages spécifiques, mais on connaît au moins les domaines.
- Avec le crawling, on ne connaît probablement pas les URL spécifiques et on ne connaît probablement pas non plus les domaines. Et c'est la raison pour laquelle on fait du crawl pour trouver les URL. Pour pouvoir en faire quelque chose plus tard. Par exemple, les moteurs de recherche utilisent le crawling pour parcourir le web afin d'indexer les pages et de les afficher dans les résultats de recherche.

Le Web scraping est-il légal ?

- Le scraping n'est pas toujours légal et les « scrapers » doivent tout d'abord respecter les droits d'auteur des sites Internet.
- Les droits sont définies suivant les pays ou le propriétaire du site
- Certains pays n'ont pas de législation sur le scraping
- En France ...
 - Le propriétaire du site web peut limiter le contenu pouvant être scrapé sur son site, en le précisant dans ses conditions générales d'utilisation.
 - L'extraction à des fins privées est autorisée, dans le respect des dispositions législatives et réglementaires en matière de droits d'auteurs et de droits voisins sur les œuvres ou les éléments incorporés dans la base.
 - L'extraction et la réutilisation d'une partie substantielle, appréciée de façon qualitative ou quantitative, à des fins exclusives d'illustration dans le cadre de l'enseignement et de la recherche et pour un public composé d'élèves, d'étudiants, d'enseignants ou de chercheurs directement concernés. Ainsi, ce cas de figure étant limité à des fins pédagogiques, il est totalement exclu de faire usage des données extraites à titre commercial par exemple.


Les freins : mesures de protections contre le Web scraping

- Utilisation de fichier robots.txt qui informe les robots (scrapers et moteurs de recherche) des pages autorisées/interdites.
- Limitation du taux de requêtes (Rate Limiting) en contrôlant le nombre de requêtes par IP sur une période donnée avec des outils comme Nginx/Apache, firewall, ou services comme Cloudflare.
- Blocage des IP suspectes
- Refus des requêtes venant d'agents non standards ou suspects comme python-requests ou curl.
- Utilisation de CAPTCHA (Completely Automated Public Turing test to tell Computers and Humans Apart) pour empêcher les robots de naviguer librement sur le site. Exemples : reCAPTCHA de Google, hCaptcha.
- Charger les données via JavaScript (AJAX, fetch), rendant le scraping plus difficile avec de simples requêtes HTML.
- Protéger les contenus sensibles derrière un mécanisme d'authentification
- Générer des jetons d'accès (tokens) temporaires et vérifier leur validité côté serveur.
- Fingerprinting et détection comportementale en identifiant les vrais navigateurs par leur empreinte (plugins, résolution, etc.) et en analysant la navigation pour repérer des mouvements "inhumains" (clics trop rapides, pas de scroll, etc.)
- Proposer une API officielle, sécurisée, bien documentée, avec authentification.
- Faire de l'obfuscation du HTML en renommant dynamiquement les classes CSS, ou en mélangeant les structures HTML.

Travaux pratiques

Scraping à partir d'une page Web avec les bibliothèques **requests** et **BeautifulSoup** de Python

Site à scraper



- <https://codeavecjonathan.com/scraping/recette/>
- Click droit >> Afficher le code source de la page / Inspecter l'élément / Inspecter

```
Console Sources Réseau Chronologies Stock
recette > Réponse
1 <!DOCTYPE html>
2 <html lang="fr">
3   <head>
4     <title>Gateau au chocolat</title>
5     <meta charset="UTF-8">
6     <link rel="stylesheet" href="recette.css"/>
7   </head>
8   <body>
9     <div class="contenu">
10
11       <div class="centre categorie">
12         <p class="categorie">Recette</p>
13       </div>
14
15       <h1>Gateau au chocolat</h1>
16
17       <div class="separateur"></div>
18
19       <!-- Mon commentaire HTML -->
20       <div class="centre">
21         <p class="description">"Cette recette facile du gateau au chocolat est un grand
22
23
```

Démarche et outils

- Processus
 - Récupérer le code HTML de la page
 - Parser le code : extraire les différents éléments du code
- Bibliothèques Python
 - **Requests** : pour faire des requêtes HTTP
 - **BeautifulSoup** : Pour extraire les éléments



Installations : VSCode et plugins

- Visual Studio Code pour Python
 - Extensions



Python Development Extensions Pack

demystifying-javascript | 532 446 | ★★☆☆☆ (9)

Everything you need for Python development. Git Extensions Pack Inclu...

Installation ✓ Mise à jour automatique ⚙



Python Debugger

Microsoft [microsoft.com](#) | 73 680 771 | ★★★★★ (12)

Python Debugger extension using debugpy.

Désactiver ▼ Désinstaller ▼ ✓ Mise à jour automatique ⚙



Python

Microsoft [microsoft.com](#) | 164 256 864 | ★★★★★ (609)

Python language support with extension access points for IntelliSense (...)

Désactiver ▼ Désinstaller ▼ Passer à la version préliminaire ✓ Mise à jour :



Jupyter

Microsoft [microsoft.com](#) | 90 204 260 | ★★☆☆☆ (331)

Jupyter notebook support, interactive programming and computing that...

Désactiver ▼ Désinstaller ▼ Passer à la version préliminaire ✓ Mise à jour :



Pylance

Microsoft [microsoft.com](#) | 136 114 548 | ★★★★★ (247)

A performant, feature-rich language server for Python in VS Code

Désactiver ▼ Désinstaller ▼ ✓ Mise à jour automatique ⚙

Création d'un nouvel environnement python

- Créer un nouvel environnement
 - `python3 -m venv ./venv`
- Activer l'environnement
 - `venv/bin/activate`
- Installer les bibliothèques requises dans l'environnement
 - `python3 -m pip install requests`
 - `python3 -m pip install beautifulsoup4`
- Sélectionner l'interpréteur de l'environnement
 - `Ctrl + Shift + P`
 - `Python select interpreter` (si l'interpréteur de l'environnement s'affiche)
 - `Enter Interpreter Path` (si l'interpréteur de l'environnement ne s'affiche pas)

Récupérer le contenu
d'une page avec une
requête HTTP

Premier code

```
• import requests
• print("Hello World")
• url =
  "https://codeavecjonathan.com/scraping
  /recette/"
  response = requests.get(url)
```


Debogage

- Placer un point d'arrêt avant la fin du code




```
8 print("FIN")
```

- Lancer l'exécution en mode debug




- Observer la variable `status_code` (en cliquant sur la flèche de gauche)
-> La valeur 200 veut dire que tout est bon



```
status_code = 200  
  
text = '<!DOCTYPE html>\n<html lang="fr">\n..  
url = 'https://codeevacionathan.com/scraping'
```


Afficher et sauvegarder le contenu de la réponse


- Affichage
 - `html = response.text`
 - `print(html)`
- Sauvegarde dans un fichier html
 - `f = open("recette.html", "w")`
 - `f.write(html)`
 - `f.close`
- Corriger l'encodage
 - `response.encoding = "utf-8 "` (Encodage utf-8)
 - `response.encoding = response.apparent_encoding` (Encodage de la page d'origine utf-8, voir la variable **apparent_encoding** dans la réponse)



Extraire les
informations

Sauvegarder le contenu

- Click droit >> Afficher le code source de la page / Inspecter l'élément / Inspecter



The screenshot shows the 'Sources' tab in a web browser's developer tools. The file 'recette' is selected, and the 'Réponse' (Response) view is active. The HTML source code is displayed, showing the following structure:

```
1 <!DOCTYPE html>
2 <html lang="fr">
3   <head>
4     <title>Gâteau au chocolat</title>
5     <meta charset="UTF-8">
6     <link rel="stylesheet" href="recette.css"/>
7   </head>
8   <body>
9     <div class="contenu">
10
11       <div class="centre categorie">
12         <p class="categorie">Recette</p>
13       </div>
14
15       <h1>Gâteau au chocolat</h1>
16
17       <div class="separateur"></div>
18
19       <!-- Mon commentaire HTML -->
20       <div class="centre">
21         <p class="description">"Cette recette facile du gateau au chocolat est un grand
22       </div>
23
```

La bibliothèque Beautifulsoup

- <https://www.crummy.com/software/BeautifulSoup/bs4/doc/>
- Titre « Making the soup »
 - `from bs4 import BeautifulSoup`
 - `with open("index.html") as fp: soup = BeautifulSoup(fp, 'html.parser')`
 - `soup = BeautifulSoup("<html>a web page</html>", 'html.parser')`

Références

- <https://github.com/scrapy/scrapy>
- <https://www.youtube.com/watch?v=sOAZpHDEdkg>
- <https://www.youtube.com/watch?v=HCV6nEACQo4&t=130s>