



TP01 : Installation de Hadoop

Téléchargements

Respecter les versions indiquées.

- Télécharger et installer Java – JDK version **8u31** -> <https://www.oracle.com/java/technologies/downloads/#java8-windows>
- Télécharger et installer Hadoop **3.2.3**. Choisir « Binary download » > « Binary » -> <https://hadoop.apache.org/releases.html>

The screenshot shows the Apache Hadoop releases page. The browser address bar displays <https://hadoop.apache.org/releases.html>. The page header includes the Apache Hadoop logo and navigation links: Download, Documentation, Community, Development, and Help. The main content area is titled "Download" and contains a table of releases. The table has five columns: Version, Release date, Source download, Binary download, and Release notes. The row for version 3.2.3, released on 2022 Mar 28, is highlighted with a red box. The "Binary download" link for this version is also highlighted with a red box.

Version	Release date	Source download	Binary download	Release notes
3.2.3	2022 Mar 28	source (checksum signature)	binary (checksum signature)	Announcement
3.3.2	2022 Mar 3	source (checksum signature)	binary (checksum signature) binary-aarch64 (checksum signature)	Announcement
2.10.1	2020 Sep 21	source (checksum signature)	binary (checksum signature)	Announcement



← → ↻ 🏠 🔒 https://www.apache.org/dyn/closer.cgi/hadoop/common/ 📄 ☆ 🔍 Rechercher 📧 ⬇️ 📁 2 📄 ☰

News About ▾ Make a Donation ▾ The Apache Way ▾ Join Us ▾ Downloads ▾ 🔍

 **COMMUNITY-LED DEVELOPMENT "THE APACHE WAY"** 

Projects ▾ People ▾ Community ▾ License ▾ Sponsors ▾

We suggest the following site for your download:

<https://dlcdn.apache.org/hadoop/common/hadoop-3.2.3/hadoop-3.2.3.tar.gz>

Alternate download locations are suggested below.

It is essential that you verify the integrity of the downloaded file using the PGP signature (`.asc` file) or a hash (`.md5` or `.sha*` file).

HTTP

<https://dlcdn.apache.org/hadoop/common/hadoop-3.2.3/hadoop-3.2.3.tar.gz>

BACKUP SITE


<https://dlcdn.apache.org/hadoop/common/hadoop-3.2.3/hadoop-3.2.3.tar.gz>



Installations et configurations

Java

Localisation de jdk : C:\Java\jdk1.8.0_31



Localisation de jre : C:\Java





Création de la variable d'environnement JAVA_HOME dans section « Variables d'utilisateur pour ... »


Modifier la variable utilisateur

Nom de la variable :

Valeur de la variable :



Modification de la variable path dans la section « Variables système »





Vérification de l'installation de java : Taper « java -version » pour s'assurer de la version installée puis « javac » sur la ligne de commande

```
Invite de commandes
Microsoft Windows [version 10.0.19043.1645]
(c) Microsoft Corporation. Tous droits réservés.

C:\Users\...>java -version
java version "1.8.0_331"
Java(TM) SE Runtime Environment (build 1.8.0_331-b09)
Java HotSpot(TM) 64-Bit Server VM (build 25.331-b09, mixed mode)

C:\Users\...>
```


```
C:\Users\...>javac
Usage: javac <options> <source files>
where possible options include:
  -g                  Generate all debugging info
  -g:none             Generate no debugging info
  -g:{lines,vars,source}  Generate only some debugging info
  -nowarn             Generate no warnings
  -verbose            Output messages about what the compiler is doing
  -deprecation        Output source locations where deprecated APIs are used
```



Hadoop

Extraire le dossier `hadoop-3.2.3.tar.gz`

Ignorer ces erreurs si elles sont affichées.





! C:\Users\mariendiaye\Downloads\hadoop-3.2.3.tar.gz: Impossible de créer le lien symbolique C:\Users\mariendiaye\Downloads\hadoop-3.2.3\lib\native\libhadoop.so
! Vous devriez peut-être exécuter WinRAR avec des droits d'administrateur
Le client ne dispose pas d'un privilège nécessaire.
! C:\Users\mariendiaye\Downloads\hadoop-3.2.3.tar.gz: Impossible de créer le lien symbolique C:\Users\mariendiaye\Downloads\hadoop-3.2.3\lib\native\libhdfspp.so
! Vous devriez peut-être exécuter WinRAR avec des droits d'administrateur
Le client ne dispose pas d'un privilège nécessaire.
! C:\Users\mariendiaye\Downloads\hadoop-3.2.3.tar.gz: Impossible de créer le lien symbolique C:\Users\mariendiaye\Downloads\hadoop-3.2.3\lib\native\libhdfs.so
! Vous devriez peut-être exécuter WinRAR avec des droits d'administrateur
Le client ne dispose pas d'un privilège nécessaire.
! C:\Users\mariendiaye\Downloads\hadoop-3.2.3.tar.gz: Impossible de créer le lien symbolique C:\Users\mariendiaye\Downloads\hadoop-3.2.3\lib\native\libnativetask.so
! Vous devriez peut-être exécuter WinRAR avec des droits d'administrateur
Le client ne dispose pas d'un privilège nécessaire.

Renommer le dossier **hadoop-x.x.x** en **hadoop** (le renommage n'est pas obligatoire).

Aller dans le dossier **hadoop\etc\hadoop** et éditer les fichiers

Nous avons 4 fichiers xml ainsi qu'un fichier cmd importants ici que nous allons éditer :

- core-site.xml


```
<configuration>
  <property>
    <name>fs.defaultFS</name>
    <value>hdfs://localhost:9000</value>
```




```
</property>  
</configuration>
```

- **hdfs-site.xml**

Tout d'abord, dans le répertoire **hadoop (hadoop-x.x.x)**, créer un répertoire nommé « **data** » et dans ce répertoire, créer deux autres répertoires nommés « **namenode** » et « **datanode** ».



Maintenant, on peut modifier le fichier.

```
<configuration>  
  <property>  
    <name>dfs.replication</name>  
    <value>1</value>  
  </property>  
  <property>  
    <name>dfs.namenode.name.dir</name>  
    <value>/C:/hadoop/data/namenode</value>  
  </property>  
  <property>
```



```
<name>dfs.datanode.data.dir</name>  
<value>/C:/hadoop/data/datanode</value>  
</property>  
</configuration>
```

- mapred-site.xml

```
<configuration>  
  <property>  
    <name>mapreduce.framework.name</name>  
    <value>yarn</value>  
  </property>  
</configuration>
```

- yarn-site.xml

```
<configuration>  
  <property>  
    <name>yarn.nodemanager.aux-services</name>  
    <value>mapreduce_shuffle</value>  
  </property><property>  
    <name>yarn.nodemanager.auxservices.mapreduce.shuffle.class</name>  
    <value>org.apache.hadoop.mapred.ShuffleHandler</value>  
  </property>  
</configuration>
```

- hadoop-env.cmd

```
set JAVA_HOME="C:\Java\jdk1.8.0_31"
```



Créer la variable d'environnement HADOOP_HOME dans section « Variables d'utilisateur pour ... »

Modifier la variable utilisateur


Nom de la variable :

Valeur de la variable :

Parcourir le répertoire... Parcourir le fichier... OK Annuler




Ajouter le chemin de HADOOP_HOME à la variable path





Ajouter le chemin de sbin à la variable d'environnement path






Remplacement du répertoire bin

- Télécharger le répertoire bin -> https://drive.google.com/file/d/19uTI2Sf7aa2aO8xJ4iukBnTYMt6_QHu/view?usp=sharing
- Décompresser le dossier « hadoop3_xFixedbin.rar»

Remplacer le repertoire « bin » de « hadoop » (« hadoop-x.x.x ») par le répertoire « bin » que vous venez de décompresser.

Formater le namenode

Lancer l'invite de commande en tant qu'administrateur.



Sur la ligne de commande, taper la commande : « **hdfs namenode -format** » Cette commande remplace « **hadoop namenode -format** » qui est dépréciée.



```
C:\WINDOWS\system32>hdfs namenode -format
2022-04-20 15:04:55,294 INFO namenode.NameNode: STARTUP_MSG:
/*****
STARTUP_MSG: Starting NameNode
STARTUP_MSG:  host = LAPTOP-JUPTA8SR/192.168.68.122
STARTUP_MSG:  args = [-format]
STARTUP_MSG:  version = 3.2.3
STARTUP_MSG:  classpath = C:\hadoop\etc\hadoop;C:\hadoop\share\hadoop\common;C:\
```


Vérifier qu'il n'y a pas d'erreur.

Lancer les services de HDFS et Yarn


- Démarrer les services de hdfs en tapant la commande `start-dfs.cmd`

Il y aura deux fenêtres qui vont s'ouvrir :

- o Une pour le **namenode**



- o Une pour le **datanode**



- Démarrer tous les services de Yarn en tapant la commande `start-yarn.cmd`

Il y aura deux fenêtres qui vont s'ouvrir :

- o Une pour le **resourcemanager**



Apache Hadoop Distribution - yarn resourcemanager

- Une pour le **nodemanager**

Sélection Apache Hadoop Distribution - yarn nodemanager

Ces commandes remplacent la commande `start-all.cmd` qui est dépréciée.

Les interfaces web de Hadoop

Hadoop offre plusieurs interfaces web pour pouvoir observer le comportement de ses différentes composantes.

- Le port **8088** permet d'afficher les informations du resource manager de Yarn et visualiser le comportement des différents jobs(avancement et résultat) en allant à l'adresse <http://localhost:8088/cluster>, comme il montre la figure ci-dessous.



← → ↺ 🏠 🛡️ 📄 localhost:8088/cluster 90 % ☆ 🔍 Rechercher 📄 📁 📄 📄



▼ Cluster

[About](#)
[Nodes](#)
[Node Labels](#)
[Applications](#)
NEW
NEW_SAVING
SUBMITTED
ACCEPTED
RUNNING
FINISHED
FAILED
KILLED
[Scheduler](#)

► Tools

Cluster Metrics

Apps Submitted	Apps Pending	Apps Running	Apps Completed	Containers Running	
0	0	0	0	0	<m

Cluster Nodes Metrics

Active Nodes	Decommissioning Nodes	Decommissioned No
0	0	0

Scheduler Metrics

Scheduler Type	Scheduling Resource Type	Minimum Allocat
Capacity Scheduler	[memory-mb (unit=Mi), vcores]	<memory:1024, vCores:1>

Show 20 ▼ entries

ID ▼	User ↕	Name ↕	Application Type ↕	Application Tags ↕	Queue ↕	Application Priority ↕	StartTime ↕	LaunchTime ↕	FinishTime ↕	§
Showing 0 to 0 of 0 entries										



- Le port **9870** qui permet d'afficher les informations de votre namenode en consultant l'adresse <http://localhost:9870>, comme il montre la figure ci-dessous.

The screenshot shows a web browser window displaying the Hadoop DFS Health Overview page. The browser's address bar shows the URL `localhost:9870/dfshealth.html#tab-overview`. The page has a green navigation bar with tabs: Hadoop, Overview (selected), Datanodes, Datanode Volume Failures, Snapshot, Startup Progress, and Utilities. The main content area is titled "Overview 'localhost:9000' (active)". Below the title is a table with the following information:

Started:	Fri Apr 22 21:40:49 +0000 2022
Version:	3.3.2, r0bcb014209e219273cb6fd4152df7df713cbac61
Compiled:	Mon Feb 21 18:39:00 +0000 2022 by chao from branch-3.3.2
Cluster ID:	CID-fe7e8d13-470e-4e33-819d-634f2acc278c
Block Pool ID:	BP-655186689-192.168.68.122-1650663634334

Below the table is a section titled "Summary" with the following text:

Security is off.
Safemode is off.



Navigation bar: < LIS Comm Regard LECTURE Hadoc hadoo Messa All Applica Nament X hadoc http Ic ubuntu + - X

Address bar: localhost:9870/dfshealth.html#tab-overview 90 % ☆ Rechercher

Menu: Hadoop Overview Datanodes Datanode Volume Failures Snapshot Startup Progress Utilities ▾

Utilities dropdown menu:

- Browse the file system
- Logs
- Log Level
- Metrics
- Configuration
- Process Thread Dump
- Network Topology

Overview 'localhost:9000' (active)

Started:	Fri Apr 22 21:40:49 +0000 2022
Version:	3.3.2, r0bcb014209e219273cb6fd4152df7df713cbac61
Compiled:	Mon Feb 21 18:39:00 +0000 2022 by chao from branch-3.3.2
Cluster ID:	CID-fe7e8d13-470e-4e33-819d-634f2acc278c
Block Pool ID:	BP-655186689-192.168.68.122-1650663634334

Summary

Security is off.

Safemode is off

localhost:9870/explorer.html

Taskbar: Windows logo, search, task view, Word, Excel, PowerPoint, File Explorer, Edge, Chrome, Firefox, VS Code, C++, C++, C++, C++, C++, 99%, battery, 18..., FRA 22:06



Après création du répertoire test

After creating the test directory, the Hadoop web interface shows the following details:

Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
drwxr-xr-x	mariendiaye	supergroup	0 B	Apr 22 22:01	0	0 B	test

Showing 1 to 1 of 1 entries

Hadoop, 2022.



Après copie du fichier data.txt

Browser tabs: Comm, Regard LECTURE, Hadoop, hadoc, Hadoop, All Applica, Browser X, hadoc, http lo, ubuntu

Address bar: localhost:9870/explorer.html#/test

Navigation: Hadoop Overview Datanodes Datanode Volume Failures Snapshot Startup Progress Utilities

Browse Directory

/test Go! [Folder] [Share] [List]

Show 25 entries Search:

	Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name	
☐	-rw-r--r--	mariendiaye	supergroup	21 B	Apr 22 22:08	1	128 MB	data.txt	

Showing 1 to 1 of 1 entries


Previous 1 Next

Hadoop, 2022.

Taskbar: Windows, Search, Task View, Word, Word, Word, File Explorer, Download, File Explorer, Firefox, Chrome, Edge, C:\A, C:\A, C:\A, C:\A, C:\A, C:\A, 99%, 18..., FRA 22:09



Au moment de l'exécution du travail (job)



Browse Directory

Go!

Show entries Search:

☐	Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name	
☐	drwxr-xr-x	mariendiaye	supergroup	0 B	Apr 22 22:08	0	0 B	test	
☐	drwx-----	mariendiaye	supergroup	0 B	Apr 22 22:11	0	0 B	tmp	

Showing 1 to 2 of 2 entries Previous 1 Next

Hadoop, 2022.





Arrêter les services

Les services de yarn

stop-yarn.cmd

```
C:\WINDOWS\system32>stop-yarn.cmd
stopping yarn daemons
La syntaxe du nom de fichier, de répertoire ou de volume est incorrecte.
Opération réussie : un signal de fin a été envoyé au processus de PID 232.
Opération réussie : un signal de fin a été envoyé au processus de PID 17692.

Information : aucune tâche en service ne correspond aux critères spécifiés.
```

Les services de hdfs

stop-dfs.cmd

```
C:\WINDOWS\system32>stop-dfs.cmd
La syntaxe du nom de fichier, de répertoire ou de volume est incorrecte.
Opération réussie : un signal de fin a été envoyé au processus de PID 11712.
Opération réussie : un signal de fin a été envoyé au processus de PID 2352.

C:\WINDOWS\system32>
```



Références

- **Tutoriel** : <https://medium.com/@pedro.a.hdez.a/hadoop-3-2-2-installation-guide-for-windows-10-454f5b5c22d3>
- Que fait la commande `hadoop namenode -format` ? <https://soluti.cyou/read-https-www.it-swarm-fr.com/fr/hadoop/que-fera-la-commande-hadoop-namenode-format/1050336765/>
- **Commandes** :
 - o <https://images.linuxide.com/hadoop-hdfs-commands-cheatsheet.pdf>
 - o <https://cwiki.apache.org/confluence/display/HADOOP2/GettingStartedWithHadoop>
- **Exercice** : <https://sysblog.informatique.univ-paris-diderot.fr/2020/03/10/hadoop-installation-sous-windows/>
- **Autres références** :
 - o <https://towardsdatascience.com/installing-hadoop-3-2-1-single-node-cluster-on-windows-10-ac258dd48aef>
 - o <https://www.c-sharpcorner.com/article/install-and-run-hadoop-on-windows-for-beginners/>
 - o <https://www.edureka.co/blog/hadoop-cluster-configuration-files/>