

Liste des contenus disponible sur [ScienceDirect](https://www.sciencedirect.com)

Méthodes et programmes informatiques en biomédecine

Page d'accueil du journal : www.elsevier.com/locate/cmpb

Diagnostic assisté par intelligence artificielle des maladies hématologiques à partir de frottis de moelle osseuse à l'aide de réseaux neuronaux profonds

Weining Wang^a, Meige Luo^a, Peirong Guo^a, Yan Wei^b, Yan Tan^b, Hongxia Shi^{b,*}^a Département d'électronique et d'informatique, Université technologique de Chine méridionale, Guangzhou, Chine^b Centre national de recherche clinique sur les maladies hématologiques, Hôpital populaire de l'université de Pékin, Pékin, Chine

Article info

Historique de l'article :

Reçu le 7 septembre 2022

Révisé le 3 décembre 2022

Accepté le 7 janvier 2023

RÉSUMÉ

Contexte et objectifs : L'examen morphologique des cellules de la moelle osseuse (MO) est essentiel tant pour le diagnostic que pour le traitement de diverses maladies hématologiques. Cependant, il est encore effectué manuellement, ce qui représente une charge de travail importante. Un système d'aide au diagnostic des cellules de la MO assisté par l'intelligence artificielle est fortement souhaité afin de réduire la charge de travail des examinateurs et d'améliorer la reproductibilité des résultats.

Méthodes : Dans cet article, nous avons proposé un système d'aide au diagnostic assisté par intelligence artificielle pour l'examen morphologique basé sur des frottis de moelle osseuse, comprenant la détection, la classification et la prédiction des types de leucémie. Pour la détection des cellules, nous avons entraîné le nouveau modèle YOLOX-s afin de localiser les cellules avec précision et d'obtenir des images de cellules individuelles. Pour la classification des cellules, nous avons considéré qu'il s'agissait d'une tâche de classification fine et avons proposé une nouvelle architecture appelée MLFL-Net utilisant des caractéristiques à plusieurs niveaux. En outre, nous avons prédit les types de leucémie sur un ensemble de données comprenant 40 personnes normales (donneurs de greffe de moelle osseuse) et 40 patients atteints de différents types de leucémie aiguë selon la norme de l'Organisation mondiale de la santé (OMS). **Résultats :** Nous avons constitué un ensemble de données à grande échelle comprenant 11 788 micrographies entièrement annotées provenant de 728 frottis et 131 300 images de cellules individuelles annotées par des experts. Avec cet ensemble de données, le modèle de détection a atteint un AUC de 0,9797 et une erreur de placement de boîte de 4,33 %. Pour la classification des cellules, la précision totale de notre MLFL-Net a atteint 89,53 %, surpassant tous les autres modèles connexes dans l'identification des catégories de cellules. Parallèlement, nous avons pris l'exemple de la leucémie aiguë pour explorer la procédure de prédiction des types de leucémie dans les maladies hématologiques. Il a généré la même prédiction diagnostique que celle donnée par les experts pour 92,5 % de la cohorte.

Conclusion : Ce système assisté par intelligence artificielle peut être mis en œuvre pour faciliter la prise de décision clinique et accélérer le diagnostic. Cette méthode contribuera à promouvoir l'intelligence et la modernisation de la cytomorphologie médullaire, qui revêt une importance capitale pour le développement de la carrière médicale.

© 2023 Publié par Elsevier B.V.

1. Introduction

L'examen morphologique des cellules de la moelle osseuse (MO) est la pierre angulaire du diagnostic et du traitement de diverses maladies hématologiques. Bien qu'il existe de nombreuses méthodes complexes, notamment la cytogénétique, l'immunophénotypage et la génétique moléculaire, l'examen morphologique reste l'élément fondamental et la première étape clé du diagnostic et du suivi de la réponse au traitement [1]. Les examinateurs observent d'abord le frottis de BM à faible grossissement afin de déterminer la meilleure région pour le comptage des cellules, puis ils utilisent un objectif 100x avec immersion dans l'huile pour distinguer et compter les différents types de cellules. En fonction des ratios clés et des informations anormales sur les cellules, les examinateurs émettent des avis diagnostiques sur différents types de maladies [2]. Cependant, un tel examen manuel

La procédure est fastidieuse, exigeante en main-d'œuvre, chronophage et dépend fortement des compétences de l'examineur [3]. Parallèlement, les résultats sont soumis à une variabilité inter et intra-évaluateurs importante [4]. Par conséquent, un système d'aide au diagnostic assisté par l'intelligence artificielle pour l'examen morphologique des cellules de la moelle osseuse est fortement souhaité afin d'améliorer l'efficacité de l'examen et de réduire la charge de travail des examinateurs, ce qui pourrait favoriser le développement de la science médicale.

À l'heure actuelle, de nombreux chercheurs ont tenté de mettre au point un examen morphologique assisté par intelligence artificielle basé sur des frottis de sang périphérique (PB) [5-8]. Cependant, par rapport aux frottis PB, les cellules des frottis BM sont plus diverses en termes de catégories et de morphologie. Par ailleurs, les cellules des frottis de BM sont généralement confrontées à des problèmes de forte densité et d'adhérence importante, ce qui augmente la difficulté de la recherche. Par conséquent, les tentatives menées sur des frottis de BM sont relativement peu nombreuses.

Parmi ces tentatives, beaucoup ont adopté des méthodes traditionnelles de segmentation et de classification des cellules à l'aide de caractéristiques artificielles.

* Auteur correspondant.

Adresse électronique : hxshi55@sina.com (H. Shi).

[9-11], qui dépendent fortement du travail manuel et sont peu robustes. Étant donné que les réseaux neuronaux convolutifs (CNN) ont connu un certain succès dans d'autres domaines du secteur médical [12,13], certains instituts ont tenté de les utiliser pour explorer les étapes clés de l'examen morphologique assisté par l'intelligence artificielle. Par exemple, Chandradevan et al. [3] ont adopté Faster R-CNN [14] pour détecter les cellules dans les images microscopiques et ont utilisé VGG-16 [15] pour les classer en 12 catégories. Fu et al. [16] ont utilisé l'algorithme de cluster K-means et l'algorithme d'arbre de décision pour segmenter les cellules et les ont classées à l'aide d'un CNN à 27 couches. Matek et al. [17] ont constitué un ensemble de données de cellules de moelle osseuse et ont utilisé ResNeXt-50 [18] pour classer les cellules en 21 catégories, dont l'ensemble de données était le plus grand pool d'images de cellules uniques de moelle osseuse annotées par des experts disponible à ce jour. Guo et al. [19] ont présenté une méthode de classification équilibrée pour classer 15 types d'ensembles de données de cellules de moelle osseuse présentant un problème de déséquilibre des classes. Maurya et al. [20] ont développé un nouveau cadre basé sur l'apprentissage automatique pour la classification d'images biologiques à partir de neuf ensembles de données différents. Ils ont classé les images hématologiques en 5 catégories et ont atteint une précision de 88 %. Cependant, les tentatives précédentes pouvaient encore être améliorées. Certaines recherches se sont concentrées sur un nombre réduit d'échantillons ou sur des catégories insuffisamment détaillées, ce qui a conduit à une polyvalence relativement faible. Parallèlement, la plupart des modèles utilisés pour la classification sont des architectures CNN classiques sans conception pertinente pour les frottis de moelle osseuse, ce qui a limité leurs performances. En outre, le système complet d'aide au diagnostic assisté par l'intelligence artificielle n'a pas encore été mis en pratique dans son intégralité. La majorité des études précédentes se sont concentrées uniquement sur une partie du système global.

Dans cet article, nous avons constitué un ensemble de données à grande échelle comprenant 11 788 micrographies entièrement annotées provenant de 728 frottis et 131 300 images de cellules individuelles annotées par des experts, qui a littéralement constitué la base importante de notre recherche. À l'aide de cet ensemble de données, nous avons exploré l'ensemble de la procédure du système d'aide au diagnostic assisté par l'intelligence artificielle basé sur des frottis de moelle osseuse, y compris la détection des cellules, la classification des cellules et la prédiction des types de leucémie. Pour la détection des cellules, nous avons formé le nouveau modèle YOLOX-s afin de localiser les cellules avec précision et d'obtenir des images de cellules individuelles. Pour la classification des cellules, contrairement à d'autres travaux connexes, nous l'avons considérée comme une tâche de classification fine. Nous avons proposé une nouvelle architecture appelée MLFL-Net utilisant des caractéristiques à plusieurs niveaux et avons obtenu une grande précision. De plus, nous avons évalué le système sur un ensemble de données comprenant 40 personnes normales (donneurs de greffe de moelle osseuse) et 40 patients atteints de différents types de leucémie aiguë selon la norme de l'Organisation mondiale de la santé (OMS) [21]. Les résultats ont montré une certaine fiabilité.

Notre étude revêt une grande importance pour le diagnostic assisté des maladies hématologiques. Les principales contributions du présent manuscrit sont les suivantes :

- Un système d'aide au diagnostic assisté par intelligence artificielle pour l'examen morphologique basé sur des frottis de moelle osseuse a été proposé, comprenant la détection des cellules, la classification et la prédiction des types de leucémie.
- Un nouveau modèle de classification appelé MLFL-Net a été proposé, qui utilise des caractéristiques à plusieurs niveaux pour classer les cellules de la moelle osseuse et obtient une grande précision pour la classification fine.
- Un ensemble de données à grande échelle a été constitué, comprenant 11 788 micrographies entièrement annotées provenant de 728 frottis et 131 300 images de cellules individuelles annotées par des experts.

2. Méthodes

Nous avons exploré l'ensemble de la procédure du système d'aide au diagnostic assisté par intelligence artificielle basé sur les frottis de moelle osseuse, y compris la détection des cellules, la classification des cellules et la prédiction des types de leucémie, comme le montre la figure 1. Dans cette section, nous présentons la construction de l'ensemble de données, la stratégie d'apprentissage du modèle de détection des cellules, le

cadre du MLFL-Net proposé et le processus de prédiction des types de leucémie.

2.1. Construction de l'ensemble de données

Les algorithmes d'apprentissage profond s'appuient sur des ensembles de données annotés à grande échelle par des experts. Nous avons donc construit un ensemble de données à grande échelle comprenant 11 788 micrographies entièrement annotées et 131 300 images de cellules individuelles annotées par des experts. Le processus de construction s'est déroulé comme suit.

Conformément au diagnostic clinique, nous avons recueilli 728 frottis de moelle osseuse à l'hôpital populaire de l'université de Pékin entre janvier 2019 et décembre 2020, provenant de 362 patients diagnostiqués avec diverses maladies hématologiques et de 366 donneurs de moelle osseuse. L'âge des participants variait de 11 à 89 ans, ce qui était tout à fait représentatif et répondait aux exigences cliniques. Il est important de noter que nous avons utilisé des frottis de moelle osseuse prélevés pour des examens antérieurs et conservés dans la base de données de l'hôpital, plutôt que de recruter spécialement des volontaires. Toutes les données ont été anonymisées et ne contiennent aucune information permettant d'identifier les personnes concernées.

Les frottis BM ont été traités par la coloration de Wright et numérisés à l'aide d'un microscope (Olympus BX50) et d'un appareil photo (JEDA SmartV 650D). Tout d'abord, l'ensemble du frottis a été photographié par des experts sous un objectif 10x dans le champ de vision du microscope afin de sélectionner la zone d'intérêt. Ensuite, 10 à 20 micrographies de chaque frottis ont été capturées sous un oculaire 10x et un objectif à immersion dans l'huile 100x.

L'ouverture numérique de l'objectif à immersion dans l'huile était de 1,3 et les dimensions des micrographies étaient de 1920 × 2560. Quelques exemples sont présentés à la figure 2A. Enfin, grâce à la l'aide du logiciel que nous avons développé, des experts ont localisé les cellules dans les micrographies et ont déterminé l'étiquette de catégorie de vérité terrain pour chaque cellule. Pour un seul frottis, nous avons obtenu le diagnostic final et 200 à 300 cellules valides avec des cadres de sélection conformément à la pratique courante.

À des fins de recherche, nous avons converti les annotations des micrographies au format VOC et recadré les cellules individuelles en fonction des annotations. Compte tenu de la qualité de l'ensemble de données, nous avons exclu les cellules floues ou dont les contours étaient incomplets. En fonction du développement et de l'évolution des cellules BM, nous avons sélectionné 19 catégories détaillées dans 5 séries cellulaires (notamment la lymphopoïèse, la plasmocytopoïèse, la granulopoïèse, la monopoïèse et l'érythroïèse) fortement corrélées au diagnostic clinique, comme le montre la figure 2B. Au final, l'ensemble de données comprenait 11 788 micrographies et 131 300 images de cellules individuelles. La distribution quantitative des cellules individuelles est illustrée à la figure 2C.

2.2. Modèle de détection cellulaire

Dans cette étude, nous avons suivi la procédure consistant à effectuer d'abord la détection, puis la classification, afin d'obtenir une meilleure précision. Au cours de la phase de détection, nous avons entraîné le modèle YOLOX-s [22] de pointe, développé par Megvii, qui offre une grande précision et une grande efficacité, afin de localiser les cellules dans les micrographies et d'obtenir les images de cellules individuelles. Le nombre de nœuds de sortie a été ajusté à 2 (représentant respectivement « Cellule » et « Non cellule ») et le seuil a été fixé à 0,4 pour la suppression non maximale (NMS). Le modèle peut générer des cadres de sélection pour les cellules détectées dans les micrographies et indiquer la probabilité que chaque cadre corresponde à une cellule réelle. Enfin, nous avons recadré les micrographies originales en fonction des cadres de sélection et avons obtenu des cellules individuelles segmentées comme entrées du modèle de classification cellulaire.

Dans cette partie, nous avons divisé notre ensemble de données micrographiques en deux ensembles, l'ensemble d'apprentissage et l'ensemble de validation, dans un rapport de 8:2. Parmi ceux-ci, 9 430 micrographies ont été utilisées pour l'apprentissage et les 2 358 autres pour l'évaluation. Le réseau a été entraîné sur PyTorch et a nécessité environ 46 heures de calcul au total. Au final, celui qui a obtenu les meilleurs résultats lors de la phase d'évaluation a été sélectionné comme modèle final.




Fig. 1. Procédure de diagnostic assistée par intelligence artificielle de l'examen morphologique. La procédure comprend la détection des cellules, la classification des cellules et la prédiction des types de leucémie. Tous les frottis ont été colorés à l'aide du colorant Wright et imagés à un grossissement de $\times 100$.

2.3. Modèle pour la classification cellulaire (MLFL-Net)

Après la phase de détection, des images de cellules individuelles ont été obtenues. L'étape cruciale de l'examen morphologique consiste à classer les cellules dans des catégories fines et correctes. Comme illustré, pour un réseau d'apprentissage profond, les niveaux supérieurs contiennent davantage d'informations sémantiques, tandis que les niveaux inférieurs contiennent davantage d'informations locales détaillées [23]. Dans le cadre de la tâche de classification fine, nous avons besoin non seulement d'informations sémantiques, mais aussi d'informations locales détaillées. C'est pourquoi nous avons conçu un nouveau modèle appelé Multi-Level Feature Learning Network (MLFL-Net) afin d'intégrer différents types d'informations en utilisant des caractéristiques à différents niveaux. Parallèlement, nous avons amélioré la caractéristique en exploitant des informations complémentaires issues des canaux, inspirées du mécanisme d'auto-attention [24,25]. À notre connaissance, le modèle proposé est le premier à agréger des informations de différentes granularités pour la classification fine des cellules BM.

Comme le montre la figure 3A, MLFL-Net comprenait le modèle de base, la branche MLFL (Multi-Level Feature Learning), la branche FID (Fusion Information Distillation) et les modules CCIM (Channel Complementary Information Mining). Plus précisément, nous avons adopté ResNet-50 [26] comme modèle de base et l'avons divisé en cinq étapes. Au lieu d'utiliser la caractéristique unique de la couche la plus profonde comme d'habitude, nous avons utilisé trois niveaux de caractéristiques provenant respectivement des blocs 2, 3 et 4 afin d'obtenir des informations avec différentes granularités. Pour mieux illustrer notre modèle, nous désignons ces trois caractéristiques respectivement par F_{low} , F_{middle} et F_{high} .

Comme illustré, différents canaux correspondent généralement à différents modèles visuels [27] et la plupart des canaux sont sémantiquement complémentaires les uns des autres. Nous avons donc construit des modules CCIM pour extraire des informations complémentaires dans différents canaux. Dans ce module, nous avons d'abord calculé les corrélations négatives entre les canaux et agrégé les informations complémentaires dans la caractéristique d'origine, comme le montre la figure 3B. Plus précisément, étant donné la caractéristique d'origine

caractéristique $F_{ori} \in R^{C \times H \times W}$, la matrice de corrélation des canaux $M_{rel} \in R^{C \times C}$ peut être calculé comme suit :

$$M_{rel} = \text{Softmax} \left(-F_{flat} F_{flat}^T \right)$$

où $F_{flat} \in R^{C \times L}$, $L = H \times W$ a été remodelé à partir de F_{ori} et F^T a été

transposées à partir de F_{flat} . La fonction Softmax a été adoptée dans la dernière dimension et le signe négatif a été conçu ici pour capturer les corrélations négatives. Après avoir obtenu M_{rel} , nous avons généré une nouvelle caractéristique avec les informations complémentaires par multiplication matricielle

. Parallèlement, nous avons agrégé la caractéristique générée avec la caractéristique d'origine afin d'éviter toute perte d'informations importantes. La

La caractéristique améliorée F_{enh} peut être calculée comme suit :

$$F_{enh} = F_{ori} + f \cdot M_{rel} \cdot F_{flat}$$

où f fait ici référence à la transformation dimensionnelle et à une couche convolutive. Nous avons envoyé F_{low} , F_{middle} et F_{high} aux modules CCIM afin d'obtenir trois caractéristiques améliorées, puis nous les avons envoyées à la branche MLFL.

La branche MLFL était composée de modules d'apprentissage des caractéristiques, de la couche GTP (global top-k pooling) [28] et de classificateurs. Le module d'apprentissage des caractéristiques, tel qu'illustré à la figure 3C, comprenait deux couches convolutives avec respectivement une taille de noyau de 1 et 3. La première était utilisée pour ajuster le nombre de canaux pour différentes caractéristiques et la seconde était utilisée pour l'extraction d'informations détaillées. Le classificateur, comme le montre la figure 3D, comprenait deux couches entièrement connectées, deux couches BN, une couche ReLU et une couche Softmax. Parallèlement, nous avons introduit le GTP pour former des vecteurs de caractéristiques, qui peuvent être considérés comme un compromis entre le pooling moyen global (GAP) et le pooling maximal global (GMP). Plus précisément, nous avons calculé la moyenne des activations top-k dans chaque canal, ce qui s'est avéré être une stratégie efficace pour une classification fine. Cela a permis d'atténuer le problème des arrière-plans complexes par rapport au GAP et d'éviter que le modèle ne perde des informations importantes par rapport au GMP. Au final, nous avons obtenu trois probabilités notées p_1 , p_2 et p_3 à partir de trois classificateurs.

Dans la branche FID, nous avons concaténé trois vecteurs de caractéristiques dans la

branche MLFL afin d'obtenir le vecteur de caractéristiques fusionné contenant des informations avec différentes granularités. À l'aide de ce vecteur de caractéristiques, nous avons formé un classificateur fusionné afin de générer une probabilité désignée par p_{concat} . Afin d'introduire les informations à différents niveaux, nous avons minimisé la divergence de Kullback-Leibler (KL) entre la probabilité de classification du classificateur fusionné et les classificateurs à différents niveaux. De cette manière, nous avons minimisé la diversité entre les différents classificateurs, ce qui peut être considéré comme une sorte de distillation des connaissances [29].

Nous avons divisé notre ensemble de données d'images unicellulaires en deux ensembles, l'ensemble d'apprentissage et l'ensemble de validation, selon un ratio de 8:2, à l'aide de la méthode d'échantillonnage hiérarchique. Avant d'entraîner le réseau, nous avons adopté l'échantillonnage aléatoire méthode de recadrage sur les données d'entrée et les avons redimensionnées au format 224×224 . Nous avons ensuite adopté des méthodes d'augmentation des données, notamment le retournement aléatoire, la rotation aléatoire et la variation aléatoire des couleurs. Nous

entraîné le modèle avec Momentum SGD. Toutes les expériences ont été

réalisées sur PyTorch.

À ce stade, nous avons adopté la perte d'entropie croisée (CE) et la perte KL pour former la fonction de perte totale. La perte totale était la suivante :

$$Perte = \alpha \cdot CE(p_{concat}, y) + \sum_{i=1}^{\#} CE(p_i, y) + \beta \cdot \sum_{i=1}^{\#} DKL(p_{concat} || p_i)$$




Fig. 2. Informations sur notre ensemble de données. (A) Trois exemples de micrographies présentant différents degrés de densité cellulaire. (B) Développement et évolution des cellules BM et 19 catégories détaillées fortement corrélées au diagnostic. (C) Répartition quantitative des cellules individuelles. Tous les frottis ont été colorés à l'aide du colorant Wright et photographiés à un grossissement de $\times 100$.

où α et β ont tous deux été fixés à 1 et γ représentait l'étiquette réelle.

Pour prédire l'étiquette d'une cellule unique, nous avons prétraité l'image et l'avons envoyée dans MLFL-Net afin d'obtenir quatre probabilités de classification différentes. Nous avons calculé la moyenne de ces quatre probabilités et sélectionné la catégorie présentant la probabilité maximale comme prédiction finale.

2.4. Prédiction des types de leucémie

Grâce aux étiquettes prédites des cellules individuelles, il est facile de calculer automatiquement les ratios clés des cellules de la moelle osseuse pour chaque frottis. En comparant les ratios clés et la norme clinique, nous pouvons prédire les types de leucémie des patients. Dans le cadre de notre travail, nous avons pris




Fig. 3. Architecture de notre modèle pour la classification fine. (A) Architecture réseau du MLFL-Net. (B) Processus du module CCIM. (C) Architecture du module FL. (D) Architecture du classificateur.

quelques cas courants de leucémie aiguë (LA) à titre d'exemple pour un système d'aide au diagnostic assisté par intelligence artificielle. La norme officielle de l'OMS [20] divise la LA en différents sous-types. Nos cas tests comprenaient quatre sous-types, à savoir la leucémie/lymphome lymphoblastique aigu, la leucémie myéloïde aigu avec maturation, la leucémie myélomonocytaire aigu et la leucémie monoblastique/monocytaire aigu, qui présentent des points de décision cliniques clairs en hématologie selon la norme de l'OMS. Il ne fait aucun doute que le système d'aide au diagnostic assisté par l'intelligence artificielle améliorera considérablement l'efficacité et l'impact favorisera le développement de la science médicale.

3. Évaluations et résultats

Nous avons mené plusieurs expériences afin d'évaluer le système d'aide au diagnostic assisté par intelligence artificielle. Tout d'abord, nous avons utilisé l'ensemble de données de micrographies pour entraîner et évaluer un nouveau modèle YOLOX-s pour la détection cellulaire. Dans un deuxième temps, nous avons mesuré les performances de notre modèle de classification MLFL-Net. Enfin, nous avons pris quelques cas de leucémie aiguë (LA) comme exemple afin de prédire les types de leucémie et d'évaluer le système d'aide au diagnostic. Toutes les expériences menées dans le cadre de ce travail ont été réalisées dans l'environnement Python à l'aide de Python 3.7, PyTorch version 1.4.0 et Cuda version 10.0. Le réseau de détection a été entraîné sur des processeurs graphiques NVIDIA Titan Xp et le réseau de classification a été entraîné sur des processeurs graphiques NVIDIA GeForce GTX 1080.

3.1. Résultats de détection

Nous avons évalué le modèle de détection dans l'ensemble de validation de 2 358 micrographies et les résultats sont présentés dans la figure 4. La moyenne en

Le temps de référence pour une micrographie était de 19,88 ms et le modèle peut détecter avec précision chaque cellule dans les micrographies. Nous avons pris trois micrographies comme exemples pour montrer nos performances de détection. La

Trois micrographies provenaient de trois patients différents présentant des degrés de densité cellulaire différents, y compris différents types de cellules. Comme le montre la figure 4, presque toutes les cellules ont été détectées avec précision, ce qui répondait aux exigences de la détection des cellules de la moelle osseuse.

Pour une évaluation quantitative, nous avons adopté la courbe précision-rappel.

[30] et l'erreur de placement du cadre de sélection [3] comme mesures d'évaluation. L'aire sous la courbe de précision-rappels (AUC) est l'un des indicateurs les plus largement utilisés pour l'évaluation des modèles. Elle mesure la précision de la détection sur une large gamme de sensibilités de détection. La figure 5A montre que notre modèle de détection a atteint une précision et un rappel élevés avec un AUC de 0,9793. En outre, nous avons utilisé l'erreur de placement des boîtes, qui est définie comme l'erreur dans la différence de positionnement entre les centres des boîtes prédites et les centres des boîtes annotées manuellement. Nous avons calculé la distance euclidienne entre les centres des boîtes et l'avons normalisée par la taille des boîtes englobantes annotées manuellement (en utilisant la moitié de la longueur de la diagonale de la boîte annotée). Le placement correct des boîtes de délimitation est essentiel pour l'étape de classification, car le centre des boîtes prédites est utilisé pour extraire des images de cellules individuelles à des fins de classification. Comme le montre la figure 5B, l'erreur relative médiane de placement des boîtes n'était que de 4,33 %, ce qui indique une bonne coïncidence entre les centres des cellules prédites et les centres réels des cellules.

3.2. Résultats de classification

Afin de prouver l'efficacité de notre MLFL-Net, nous l'avons évalué sur l'ensemble de validation de cellules individuelles. Afin de présenter directement les performances, nous avons représenté la matrice de confusion du MLFL-Net dans la figure 6. La couleur intense dans la diagonale principale représente ici que la plupart des échantillons ont été correctement prédits, ce qui prouve clairement l'efficacité de notre modèle.

Pour une évaluation quantitative, nous avons adopté l'exactitude, la précision et le rappel comme mesures d'évaluation, définies comme suit :

échantillons corrects

$$\text{précision} = \frac{\text{nombre total d'échantillons}}{\text{vrais positifs}}$$

$$\text{précision} = \frac{\text{vrais positifs}}{\text{vrais positifs} + \text{faux positifs}}$$

$$\text{rappel} = \frac{\text{vrai positif}}{\text{vrai positif} + \text{faux négatif}}$$




Fig. 4. Résultats de la détection des cellules. Trois exemples de micrographies et les cadres de délimitation détectés dans celles-ci. Dans les micrographies présentant différents degrés de densité cellulaire, les cadres de délimitation correspondaient largement à la réalité.




Fig. 5. Résultats de la détection des cellules. (A) Précision-rappel de l'algorithme de détection. (B) Histogramme de l'erreur de placement des cadres de sélection. Cette erreur mesure la distance entre les centres des cadres de sélection prédits et réels par rapport à la taille réelle des cadres de sélection.

où les vrais positifs et les vrais négatifs sont définis comme le nombre d'images classées ou non classées, respectivement, dans une classe donnée en accord avec la vérité terrain. De même, les faux positifs

et les faux négatifs désignent respectivement le nombre d'images classées ou non classées dans une classe donnée en désaccord avec la vérité terrain [17].

Concrètement, nous avons calculé la précision de notre modèle ainsi que le rappel et la précision moyens pour chaque catégorie. La précision totale de notre modèle a atteint 89,53 %. Le [tableau 1](#) présente respectivement la précision et le rappel de chaque catégorie. Sur les 19 classes totales, 8 classes de cellules avaient une précision supérieure à 90 % et toutes les classes de cellules avaient une précision supérieure à 75 %. En ce qui concerne le rappel, 8 classes de cellules avaient un rappel supérieur à 90 % et seul le rappel des monoblastes était inférieur à 70 %. De plus, nous avons comparé notre modèle MLFL-Net à d'autres modèles de classification récents. Nous avons mené des expériences sur notre ensemble de données à l'aide de différents modèles et les résultats sont présentés dans le [tableau 2](#). WBCNet [31] était un modèle auto-construit utilisant des réseaux classiques comme référence pour la classification des globules blancs et a atteint une précision de 85,49 %, soit 4,04 % de moins que la précision de notre modèle.

MMAL-Net [32] était bien conçu avec un mécanisme d'attention pour une classification fine. Il a obtenu d'excellentes performances.




Fig. 6. Matrice de confusion de notre modèle MLFL-Net dans notre ensemble de validation. La couleur bleu foncé dans les entrées diagonales de la matrice indique une grande précision. Les abréviations des noms des cellules sont utilisées dans la figure. (Les abréviations et les noms correspondants sont répertoriés ici : MLB : myéloblaste, PLM : promyélocyte, MYE : myélocyte, MET : métamyélocyte, BN : neutrophile en bande, SN : neutrophile segmenté, EOS : éosinophile, BAS : basophile, PEB : proérythroblaste, BEA : érythroblaste basophile, PEB : érythroblaste polychromatique, OEB : érythroblaste orthochromatique, ILY : lymphocyte immature, LY : lymphocyte, MOB : monoblaste, POM : promonocyte, MON : monocyte, IPC : plasmocyte immature, PC : plasmocyte).

Tableau 1
Précision et rappel du classificateur par classe.

Classe	Précision	Rappel
Myéloblaste	0,8930	0,9026
Promyélocyte	0,8955	0,9160
Myélocyte	0,8838	0,8761
Métamyélocyte	0,7644	0,8122
Neutrophile en bande	0,8444	0,8067
Neutrophiles segmentés	0,9101	0,9212
Éosinophiles	0,9760	0,9760
Basophiles	0,9310	0,7606
Proérythroblaste	0,7671	0,7089
Érythroblaste basophile	0,8179	0,7968
Érythroblaste polychromatique	0,9119	0,8973
Érythroblaste orthochromatique	0,9224	0,9340
Lymphocyte immature	0,9487	0,9676
Lymphocytes	0,9580	0,9531
Monoblastes	0,7558	0,6944
Promonocyte	0,7673	0,7334
Monocyte	0,8289	0,7037
Plasmocytes immatures	0,8908	0,9677
Cellule plasmatique	0,9526	0,8664

Tableau 2
Comparaison de la précision avec d'autres méthodes.

Modèle	Précision (%)
WBCNet	85,49
MMAL-Net	84,35
ResNet-50	87,07
MLFL-Net (notre modèle proposé)	89,53

dans l'ensemble de données d'images générales à haute résolution, mais n'a obtenu qu'une précision de 84,35 % sur notre ensemble de données, soit 5,18 % de moins que notre modèle. Les résultats de WBCNet et MMAL-Net ont montré que l'application directe des modèles existants donnait de mauvais résultats pour la classification des cellules. Nous avons également comparé notre modèle à ResNet-50 [26] et la précision de notre modèle était supérieure de 2,46 % à celle de ResNet-50, ce qui prouve que le réseau conçu pour les cellules BM était meilleur que les architectures CNN classiques. Les résultats présentés dans le [tableau 2](#) montrent que notre méthode proposée surpassait toutes les autres méthodes.

De plus, afin de tester la généralisation de notre MLFL-Net, nous avons évalué notre modèle sur l'ensemble de données de cellules BM publié par Matek et al. [17]. Nous avons sélectionné au hasard 80 % des images disponibles dans chaque classe pour l'entraînement, tandis que 20 % ont été utilisées pour l'évaluation du réseau entraîné. Dans une comparaison directe des performances du modèle séquentiel ResNeXt-50 utilisé par Matek et al. [17] et de notre MLFL-Net, ce dernier a surpassé ResNeXt-50 dans la plupart des classes, comme le montre [la figure 7](#). Les rappels de MLFL-Net pour la plupart des catégories étaient beaucoup plus élevés que ceux de ResNeXt-50. Les blastes et les neutrophiles segmentés ont notamment enregistré la plus forte amélioration (23 %). Dans l'ensemble, au cours de la période d'évaluation, nous avons obtenu une précision totale de 89,09 %. Nous avons calculé la précision totale en fonction de la précision et du rappel rapportés par Matek et al. et avons obtenu un résultat de 72,28 %, bien inférieur à notre résultat. Cela prouve clairement l'efficacité de notre MLFL-Net.

À l'heure actuelle, de nombreux chercheurs étudient l'interprétabilité des CNN, et Grad-CAM [33] est un outil de visualisation réputé et largement utilisé. Pour une image en entrée, il peut générer une carte thermique dans laquelle les zones aux couleurs plus foncées représentent les zones considérées comme plus importantes. Afin d'illustrer les régions importantes, nous l'avons utilisé pour visualiser quatre cellules de types différents et les cartes thermiques sont présentées à [la figure 8](#). La première ligne montre l'image originale, tandis que les deuxième, troisième et quatrième lignes représentent respectivement le niveau faible, le niveau moyen et le niveau élevé. [La figure 8A](#) nous permet de constater que les trois niveaux se concentrent sur différentes zones des cellules.

Tableau 3
Résultat du diagnostic assisté pour la leucémie aiguë.

Types	Nombre total	Correct	Faux
Leucémie lymphoblastique aiguë/lymphome	16	16	0
Leucémie myéloïde aiguë avec maturation	16	14	2
Leucémie myélomonocytaire aiguë	5	1	4
Leucémie monoblastique/monocytaire aiguë	3	3	0
Normal	40	40	0
Total	80	74	6

et obtenu des informations avec différents niveaux de granularité, ce qui a prouvé que notre MLFL-Net peut se concentrer respectivement sur le contour cellulaire, le cytoplasme et le noyau à un niveau faible, moyen et élevé. En concaténant les trois niveaux de granularité des cellules, le réseau a obtenu des informations plus complètes sur les cellules, ce qui a prouvé dans une certaine mesure l'efficacité de notre méthode.

Par ailleurs, afin de démontrer directement l'efficacité de notre modèle, nous avons extrait les vecteurs de caractéristiques dans la branche FID et réduit les dimensions de 3072 à 2 à l'aide de l'algorithme UMAP (Uniform Manifold Approximation and Projection) [34]. [La figure 8B](#) montre le résultat de la projection, chaque point représentant une cellule unique. La figure permet de constater facilement que chaque classe possède son propre espace de caractéristiques, ce qui signifie que le classificateur peut généralement bien séparer les classes individuelles grâce aux caractéristiques extraites. Cependant, certaines classes étaient proches d'autres classes dans l'espace d'intégration des caractéristiques, ce qui illustre un degré élevé de confusion entre ces classes.

3.3. Résultats de prédiction des maladies

Après les étapes de détection et de classification, nous avons obtenu des cellules individuelles et leurs catégories dans chaque micrographie, ce qui nous a permis d'obtenir facilement les proportions des différents types de cellules pour chaque patient. Nous avons ainsi pu prédire les types de leucémie en fonction de la proportion des différentes cellules. Nous avons pris quelques cas de leucémie aiguë (LA) comme exemple pour évaluer le système d'aide au diagnostic.

Nous avons utilisé un ensemble de données comprenant 40 patients atteints de leucémie aiguë (LA) et 40 personnes normales (donneurs de greffe de moelle osseuse) pour évaluer l'efficacité de notre méthode. Nous avons suivi la procédure d'aide au diagnostic consistant à détecter les cellules, à les classer et à prédire les types de leucémie selon la norme de l'OMS [21]. Par exemple, lorsque la proportion de lymphocytes immatures est supérieure à 20 %, l'ordinateur donne un résultat de prédiction « leucémie lymphoblastique aiguë ». Lorsque la proportion de monoblastes et de promonocytes est supérieure à 20 %, l'ordinateur donne un résultat de prédiction « leucémie monoblastique/monocytaire aiguë ».

Comme le montre [le tableau 3](#), quarante personnes normales ont été prédites de manière totalement correcte, ce qui prouve la grande efficacité de notre procédure pour distinguer les personnes normales des patients. Pour le diagnostic de différents patients atteints d'AL, certaines maladies ont atteint une précision de 100 %, notamment la leucémie lymphoblastique aiguë/le lymphome et la leucémie monoblastique/monocytaire aiguë. Par ailleurs, certains patients atteints de leucémie myélomonocytaire aiguë ont été prédits comme atteints de leucémie myéloïde aiguë avec maturation. Cela s'explique par une performance de classification des monoblastes plus faible, où de nombreux monoblastes ont été classés dans les myéloblastes, à l'instar des hématopathologistes experts. En général, la précision totale était de 92,5 %, ce qui reflète le potentiel du diagnostic assisté.

Dans l'ensemble, dans le système d'aide au diagnostic assisté par l'intelligence artificielle, le nouveau modèle YOLOX-s a détecté les cellules avec précision et obtenu des images de cellules individuelles. Notre modèle MLFL-Net a obtenu une précision totale de 89,53 % et a surpassé les autres modèles. De plus, 92,5 % des résultats de prédiction pour la cohorte étaient cohérents avec ceux fournis par les experts. Notre étude revêt une grande importance pour le diagnostic assisté des maladies hématologiques.




Fig. 7. Comparaison du rappel pour chaque classe dans trois modèles différents sur l'ensemble de données de cellules BM publié par Matek et al.




Fig. 8. Visualisation des caractéristiques. (A) Quatre cellules de types différents et cartes thermiques des caractéristiques à différents niveaux. (B) Intégration UMAP des caractéristiques extraites dans la branche FID.

4. Discussion

Dans cet article, nous présentons un système d'aide au diagnostic assisté par l'intelligence artificielle pour l'examen morphologique basé sur des frottis de moelle osseuse, comprenant la détection, la classification et la prédiction des types de leucémie. Ce système a donné de bons résultats, avec une précision et une exactitude élevées tant pour la détection que pour la classification des cellules. Parallèlement, nous avons constitué un ensemble de données à grande échelle et bien annoté sur les cellules de la moelle osseuse, composé de 11 788 micrographies et 131 300 images de cellules individuelles, qui a constitué la base solide de notre étude.

Nous avons suivi la procédure consistant à effectuer d'abord la détection, puis la classification. Nous avons utilisé l'ensemble de données de micrographies pour entraîner et évaluer un nouveau modèle YOLOX-s pour la détection des cellules. Les résultats ont été remarquables, avec une grande précision malgré le fait que les images présentaient différents degrés de densité cellulaire, qui constituait la base de la classification des cellules. La classification des cellules de la moelle osseuse est l'une des étapes les plus importantes du processus de diagnostic. Nous l'avons considérée comme une tâche de classification fine et avons proposé une nouvelle architecture appelée MLFL-Net, qui a été la première à adopter des caractéristiques à plusieurs niveaux pour la classification des cellules de la moelle osseuse à notre connaissance. Les résultats obtenus dans notre ensemble de données ont été encourageants, avec une grande précision, surpassant le modèle de référence et d'autres modèles connexes. Parallèlement, les valeurs de rappel et de précision étaient suffisamment élevées pour répondre à la demande en matière d'aide au diagnostic. Après les étapes de détection et de classification, chaque cellule des micrographies a été classée dans une catégorie spécifique. Ensuite, la clé

Les ratios des différentes catégories de cellules pour chaque frottis de moelle osseuse ont été calculés, ce qui constituait des preuves importantes pour la prédiction de la maladie. Nous avons évalué l'ensemble de la procédure d'aide au diagnostic sur 40 lames provenant de différents types de patients atteints d'AL et 40 lames provenant de donneurs. Selon la norme de l'OMS pour la prédiction de l'AL, notre méthode a atteint une précision totale de 92,5 %, ce qui démontre son potentiel en matière d'aide au diagnostic.

À l'heure actuelle, notre système peut fournir une aide au diagnostic pour certains types de leucémie lorsque les micrographies de la moelle osseuse du patient sont disponibles. Cependant, notre système peut encore être amélioré. Par exemple, le problème de déséquilibre dans la classification est un problème notoire dans les études sur la moelle osseuse basées sur l'IA. Certaines classes, comme les basophiles et les proérythroblastes, ont obtenu une précision relativement faible. Cela est probablement dû à la rareté de ces objets, et les performances pourraient s'améliorer avec l'accès à de grands ensembles de données d'apprentissage. En outre, en raison de leur structure similaire à celle des granulocytes, de nombreux monocytes, notamment les monoblastes, les promonocytes et les monocytes, ont été classés à tort dans la catégorie des granulocytes, ce qui a conduit à un rappel relativement faible dans ces classes, comme c'est le cas chez les hématopathologistes experts. À l'avenir, nous essaierons d'autres méthodes pour améliorer la précision de la classification, notamment en nous concentrant davantage sur les classes de cellules facilement confondables et en complétant les données, y compris diverses maladies et les cellules anormales, afin de les rendre plus universelles.

En attendant, l'adaptabilité du système doit être améliorée. Il existe de grandes différences dans les images de la moelle osseuse recueillies.

provenant de différents appareils avec différentes résolutions et nuances de coloration de l'. Par conséquent, afin de conserver un résultat de classification précis, le modèle doit être réentraîné avec de nouvelles données avant d'être prêt pour un hôpital donné. Il est fastidieux et peu pratique de collecter et de traiter des données d'apprentissage pour chaque hôpital. C'est pourquoi nous allons introduire un mécanisme de normalisation de la coloration et des méthodes d'adaptation de domaine afin d'améliorer la robustesse de notre méthode à l'avenir. De même, une autre limite est que notre système d'aide au diagnostic ne peut fournir que des informations morphologiques aux médecins. Dans la pratique clinique, les médecins combinent les résultats de plusieurs examens pour établir un diagnostic. En outre, nous prévoyons d'inclure des données issues de la cytométrie en flux ou de la génétique moléculaire dans nos méthodes afin de construire un réseau d'apprentissage profond multimodal et d'améliorer l'intégrité de la procédure.

Déclaration d'intérêts concurrents

Les auteurs déclarent n'avoir aucun conflit d'intérêts susceptible d' r ce travail. Nous déclarons n'avoir aucun intérêt commercial ou associatif représentant un conflit d'intérêts en rapport avec le travail soumis.

Remerciements

Ce travail a été soutenu par la Fondation des sciences naturelles de la province du Guangdong en Chine (n° 2021A1515011888).

Références

- [1] A.V. Hoffbrand, P. Vyas, E. Campo, H. Torsten, G. Keith, Les néoplasmes hématologiques : techniques de laboratoire et leucémie myéloïde aiguë, Atlas en couleurs de l'hématologie clinique : bases moléculaires et cellulaires de la maladie, 5e éd., John Wiley & Sons, 2019, pp. 198-229.
- [2] S.H. Swerdlow, E. Campo, S.A. Pileri, et al., Révision 2016 de la classification des néoplasmes lymphoïdes de l'Organisation mondiale de la santé (), Blood 127 (20) (2016) 2375–2390.
- [3] R. Chandradevan, A.A. Aljudi, B.R. Drumheller, et al., Détection, mesure et classification automatisées des comptages différentiels des aspirats de moelle osseuse : développement initial axé sur les cellules non néoplasiques, Lab. Invest. 100 (1) (2020) 98–109.
- [4] X. Fuentes-Arderiu, D. Dot-Bach, Incertitude de mesure dans le comptage différentiel manuel des leucocytes, Clin. Chem. Lab. Med. 47 (1) (2009) 112–115.
- [5] C. Matek, S. Schwarz, K. Spiekermann, et al., Reconnaissance au niveau humain des cellules blast es dans la leucémie myéloïde aiguë à l'aide de réseaux neuronaux convolutifs, Nat. Mach. Intell. 1 (11) (2019) 538–544.
- [6] P. Tiwari, J. Qian, Q. Li, et al., Détection des sous-types de cellules sanguines à l'aide de l'apprentissage profond, Cogn. Syst. Res. 52 (1) (2018) 1036–1044.
- [7] R.B. Hegde, K. Prasad, H. Hebbar, et al., Développement d'un algorithme robuste pour la détection d' s de noyaux et la classification des globules blancs dans les images de frottis sanguins périphériques, J. Med. Syst. 42 (6) (2018) 1–8.
- [8] R.B. Hegde, K. Prasad, H. Hebbar, B.M. Ku, Comparaison entre le traitement traditionnel des images et les approches d'apprentissage profond pour la classification des globules blancs dans les images de frottis sanguins périphériques, Biocybern. Biomed. Eng. 39 (2) (2019) 382–392.
- [9] N. Theera-Umpon, S. Dhompongsa, Caractéristiques granulométriques morphologiques du noyau d' s dans la classification automatique des globules blancs de la moelle osseuse, IEEE Trans. Inf. Technol. Biomed. 11 (3) (2007) 353–359.
- [10] N.D. Pergad, S.T. Hamde, Réseau neuronal à base radiale avec recherche gravitationnelle fractionnaire pour la classification des globules blancs de la moelle osseuse, Imaging Sci. J. 66 (2) (2018) 106–124.
- [11] V.G. Nikitayev, A.N. Pronichev, N.N. Tupitsin, et al., Classification of bone mar- row cells in the diagnosis of acute lymphoblastic leukemia, J. Phys. Conf. Ser. 2058 (1) (2021) 012043.
- [12] J. He, S.L. Baxter, J. Xu, et al., La mise en œuvre pratique des technologies d'intelligence artificielle en médecine, Nat. Med. 25 (1) (2019) 30–36.
- [13] A. Esteve, B. Kuprel, R.A. Novoa, et al., Classification du cancer de la peau au niveau dermatologique à l'aide de réseaux neuronaux profonds, Nature 542 (7639) (2017) 115–118.
- [14] S. Ren, K. He, R. Girshick, J. Sun, Faster R-CNN : vers la détection d'objets en temps réel à l'aide de réseaux de proposition de régions, IEEE Trans. Pattern Anal. Mach. Intell. 39 (6) (2017) 1137–1149 1er juin, doi:10.1109/TPAMI.2016.2577031.
- [15] K. Simonyan, A. Zisserman, Réseaux convolutifs très profonds pour la reconnaissance d'images à grande échelle, dans : Actes de la Conférence internationale sur l'apprentissage des représentations, dans Conférence internationale sur l'apprentissage des représentations, mai 2015.
- [16] X. Fu, M. Fu, Q. Li, X. Peng, J. Lu, F. Fang, M. Chen, Réseaux convolutifs très profonds pour la reconnaissance d'images à grande échelle. Conférence internationale sur l'apprentissage des représentations, Acta Cytol. 64 (6) (2020) 588–596, doi:10.1159/000509524.
- [17] C. Matek, S. Krappe, C. Münzenmayer, T. Haferlach, C. Marr, Différenciation très précise des morphologies des cellules de la moelle osseuse à l'aide de réseaux neuronaux profonds sur un vaste ensemble de données d'images, Blood 138 (20) (2021) 1917–1927, doi:10.1182/blood.2020010568.
- [18] S. Xie, R. Girshick, P. Dollár, Z. Tu, K. He, Transformations résiduelles agrégées pour les réseaux neuronaux profonds, dans : Actes de la conférence IEEE sur la vision par ordinateur et la reconnaissance des formes (CVPR), 2017, pp. 5987-5995, doi:10.1109/CVPR.2017.634.
- [19] L. Guo, P. Huang, D. Huang, et al., Une méthode de classification pour classer les cellules de moelle osseuse présentant un problème de déséquilibre des classes, Biomed. Signal Process. Control 72 (A) (2022) 103296.
- [20] R. Maurya, V.K. Pathak, R. Burget, Malay Kishore Dutta, Détection automatisée d'images biologiques à l'aide d'un nouvel algorithme de fusion de caractéristiques profondes et d'une approche efficace de sélection de caractéristiques à haute dimension, Comput. Biol. Med. 137 (2021) 104862.
- [21] S.H. Swerdlow, E. Campo, N.L. Harris, E.S. Jaffe, S.A. Pileri, H. Stein, J. Thiele, Classification OMS des tumeurs des tissus hématopoïétiques et lymphoïdes, Classification OMS des tumeurs, 4e éd., CIRC, 2017.
- [22] Ge Z., Liu S., Wang F., et al, YOLOX : dépasser la série YOLO en 2021, <https://arxiv.org/pdf/2107.08430.pdf>. Consulté le 18 juillet 2021.
- [23] R. Du, J. Xie, Z. Ma, et al., Progressive learning of category-consistent multi- pour une classification visuelle fine, IEEE Trans. Pattern Anal. Mach. Intell. (2021) Sous presse.
- [24] X. Wang, R. Girshick, A. Gupta, et al., Non-local neural networks, dans : Actes de la conférence IEEE/CVF sur la vision par ordinateur et la reconnaissance des formes (CVPR), 2018, pp. 7794–7803, doi:10.48550/arXiv.1711.07971.
- [25] J. Fu, J. Liu, H. Tian, et al., Dual attention network for scene segmentation, dans : Proceedings of the IEEE/CVF conference on computer vision and pattern recognition (CVPR), 2019, pp. 3146–3154, doi:10.48550/arXiv.1809.02983.
- [26] K. He, X. Zhang, S. Ren, et al., Deep residual learning for image recognition, dans : Proceedings of the IEEE conference on computer vision and pattern recognition (CVPR), 2016, pp. 770–778, doi:10.1109/CVPR.2016.90.
- [27] Yosinski J., Clune J., Nguyen A., et al, Comprendre les réseaux neuronaux grâce à la visualisation approfondie, <https://arxiv.org/pdf/1506.06579.pdf>. Consulté le 22 juin 2015.
- [28] H. Hanselmann, H. Ney, Elope : classification visuelle fine avec localisation, regroupement et intégration efficaces, dans : Actes de la conférence d'hiver de l'IEEE sur les applications de la vision par ordinateur (WACV), 2020, pp. 1236-1245, doi:10.1109/WACV45572.2020.9093601.
- [29] Geoffrey H., Vinyals O. et Dean J., Distilling the knowledge in a neural network, <https://arxiv.org/pdf/1503.02531.pdf>. Consulté le 9 mars 2015.
- [30] J. Davis, M. Goadrich, The relationship between Precision-Recall and ROC curves, dans : Proceedings of the 23rd international conference on Machine learning, 2006, pp. 23–40.
- [31] M. Jiang, L. Cheng, F. Qin, et al., Classification des globules blancs à l'aide de réseaux neuronaux convolutifs profonds, Int. J. Pattern Recognit. Artif. Intell. 32 (09) (2018) 1–9.
- [32] F. Zhang, M. Li, G. Zhai, et al., Apprentissage multi-branches et multi-échelles pour une catégorisation visuelle fine, dans : Actes de la Conférence internationale sur la modélisation multimédia (MMM), 2021, pp. 136–147, doi:10.1007/ 978- 3- 030-67832- 6_12.
- [33] R.R. Selvaraju, M. Cogswell, A. Das, et al., Grad-CAM : explications visuelles à partir de réseaux profonds via la localisation basée sur les gradients, dans : Actes de la Conférence internationale IEEE sur la vision par ordinateur (ICCV), 2017, pp. 618-626, doi:10.1109/ICCV.2017.74.
- [34] L. McInnes, J. Healy, N. Saul, L. Großberger, UMAP : approximation et projection uniformes de variétés, J. Open Source Softw. 3 (29) (2018) 861.