

Parfait — application complète du filtrage collaboratif (approche basée sur les utilisateurs)

Parfait — voici une application complète du filtrage collaboratif (approche basée sur les utilisateurs), calculée à la main et expliquée pas-à-pas. On prédit la note qu'un utilisateur donnerait à un film manquant en utilisant la similarité de Pearson (centrée sur la moyenne) et une combinaison pondérée.

Contexte et jeu de données

On a 4 utilisateurs $U_1, \dots, U_4$ et 5 items $I_1, \dots, I_5$. Les étoiles (notes) vont de 1 à 5 ; un « — » signifie note manquante.

Utilisateur	I_1	I_2	I_3	I_4	I_5
U_1	5	3	4	4	—
U_2	3	1	2	3	3
U_3	4	3	4	3	5
U_4	3	3	1	5	4

TABLE 1 – Notes des utilisateurs sur les items

Objectif : prédire la note de U_1 pour I_5 (c'est la cellule manquante).

Vue d'ensemble de la méthode (user-based, Pearson)

1. Calculer la moyenne des notes de chaque utilisateur $\bar{r}_u$.
2. Pour chaque autre utilisateur v , calculer la corrélation de Pearson entre U_1 et v sur les items co-notés. Formule (sur items co-notés C) :

$$\text{sim}(u, v) = \frac{\sum_{i \in C} (r_{u,i} - \bar{r}_u)(r_{v,i} - \bar{r}_v)}{\sqrt{\sum_{i \in C} (r_{u,i} - \bar{r}_u)^2} \sqrt{\sum_{i \in C} (r_{v,i} - \bar{r}_v)^2}}.$$

3. Prédiction pour U_1, I_5 (forme centrée) :

$$\hat{r}_{1,5} = \bar{r}_1 + \frac{\sum_v \text{sim}(1, v) (r_{v,5} - \bar{r}_v)}{\sum_v |\text{sim}(1, v)|},$$

(somme sur les voisins ayant noté I_5 ; on peut restreindre aux k plus similaires).

1) Moyennes des utilisateurs

Calcul des moyennes sur les notes existantes :

$$\begin{aligned}\bar{r}_1 &= (5 + 3 + 4 + 4)/4 = 16/4 = 4.0, \\ \bar{r}_2 &= (3 + 1 + 2 + 3 + 3)/5 = 12/5 = 2.4, \\ \bar{r}_3 &= (4 + 3 + 4 + 3 + 5)/5 = 19/5 = 3.8, \\ \bar{r}_4 &= (3 + 3 + 1 + 5 + 4)/5 = 16/5 = 3.2.\end{aligned}$$

2) Déviations (notes centrées)

Pour les items co-notés entre U_1 et les autres on prend I_1, I_2, I_3, I_4 .

Déviations de U_1 (par rapport à $\bar{r}_1 = 4.0$) :

$$I_1 : 5 - 4 = +1,$$

$$I_2 : 3 - 4 = -1,$$

$$I_3 : 4 - 4 = 0,$$

$$I_4 : 4 - 4 = 0.$$

Déviations de U_2 (par rapport à $\bar{r}_2 = 2.4$) :

$$I_1 : 3 - 2.4 = +0.6,$$

$$I_2 : 1 - 2.4 = -1.4,$$

$$I_3 : 2 - 2.4 = -0.4,$$

$$I_4 : 3 - 2.4 = +0.6.$$

Déviations de U_3 (par rapport à $\bar{r}_3 = 3.8$) :

$$I_1 : 4 - 3.8 = +0.2,$$

$$I_2 : 3 - 3.8 = -0.8,$$

$$I_3 : 4 - 3.8 = +0.2,$$

$$I_4 : 3 - 3.8 = -0.8.$$

Déviations de U_4 (par rapport à $\bar{r}_4 = 3.2$) :

$$I_1 : 3 - 3.2 = -0.2,$$

$$I_2 : 3 - 3.2 = -0.2,$$

$$I_3 : 1 - 3.2 = -2.2,$$

$$I_4 : 5 - 3.2 = +1.8.$$

3) Similarités (Pearson) entre U_1 et les autres

sim(U_1, U_2)

Numérateur :

$$(1)(0.6) + (-1)(-1.4) + (0)(-0.4) + (0)(0.6) = 0.6 + 1.4 + 0 + 0 = 2.0.$$

Dénominateur :

$$\sqrt{1^2 + (-1)^2 + 0^2 + 0^2} \times \sqrt{0.6^2 + (-1.4)^2 + (-0.4)^2 + 0.6^2} = \sqrt{2} \times \sqrt{2.84} \approx 1.41421356 \times 1.685088 \approx 2.38327506$$

Donc

$$\text{sim}(U_1, U_2) \approx \frac{2.0}{2.38327506} \approx 0.83918.$$

sim(U_1, U_3)

Numérateur :

$$(1)(0.2) + (-1)(-0.8) + 0 \cdot 0.2 + 0 \cdot (-0.8) = 0.2 + 0.8 + 0 + 0 = 1.0.$$

Dénominateur :

$$\sqrt{2} \times \sqrt{0.2^2 + (-0.8)^2 + 0.2^2 + (-0.8)^2} = \sqrt{2} \times \sqrt{1.36} \approx 1.41421356 \times 1.16619 \approx 1.64924225.$$

Donc

$$\text{sim}(U_1, U_3) \approx \frac{1.0}{1.64924225} \approx 0.60634.$$

sim(U_1, U_4)

Numérateur :

$$(1)(-0.2) + (-1)(-0.2) + 0(-2.2) + 0(1.8) = -0.2 + 0.2 + 0 + 0 = 0.0.$$

D'où

$$\text{sim}(U_1, U_4) = 0.$$

(Aucune corrélation linéaire détectée sur les co-notations.)

4) Prévion de $r_{1,5}$ (note de U_1 sur I_5)

Formule (centrée, pondérée par similarités) :

$$\hat{r}_{1,5} = \bar{r}_1 + \frac{\sum_v \text{sim}(1, v) (r_{v,5} - \bar{r}_v)}{\sum_v |\text{sim}(1, v)|},$$

on somme sur les v qui ont noté I_5 (ici U_2, U_3, U_4) ; mais $\text{sim}(U_1, U_4) = 0$, donc il n'apporte rien.

Déviations pour I_5 :

$$U_2 : r_{2,5} - \bar{r}_2 = 3 - 2.4 = 0.6,$$

$$U_3 : 5 - 3.8 = 1.2,$$

$$U_4 : 4 - 3.2 = 0.8 \quad (\text{mais sim} = 0).$$

Calcul du numérateur pondéré :

$$\text{num} = 0.83918 \cdot 0.6 + 0.60634 \cdot 1.2 + 0 \cdot 0.8.$$

Calcul strict :

$$0.83918 \times 0.6 \approx 0.503508, \quad 0.60634 \times 1.2 \approx 0.727607,$$

donc

$$\text{num} \approx 0.503508 + 0.727607 = 1.231115.$$

Dénominateur = somme des valeurs absolues des similarités utilisées :

$$\text{den} = |0.83918| + |0.60634| + |0| \approx 0.83918 + 0.60634 = 1.44552.$$

Contribution centrée = $\text{num}/\text{den} \approx 1.231115/1.44552 \approx 0.85168$.

Donc prédiction :

$$\hat{r}_{1,5} = \bar{r}_1 + 0.85168 = 4.0 + 0.85168 = 4.85168.$$

On peut arrondir à 4.85 (ou à 5 si l'on veut une note entière). Interprétation : on s'attend à ce que U_1 aime I_5 (note élevée).

Filtrage collaboratif (approche user-based) — similarité cosinus

Refaisons l'exercice précédent, mais en utilisant la *similarité cosinus* entre vecteurs de notes (calculée sur les items co-notés). Ici nous utiliserons les vecteurs de notes brutes (non centrées) sur les items co-notés I_1, I_2, I_3, I_4 . L'objectif reste : prédire la note de U_1 pour I_5 .

Jeu de données (rappel)

Utilisateur	I_1	I_2	I_3	I_4	I_5
U_1	5	3	4	4	—
U_2	3	1	2	3	3
U_3	4	3	4	3	5
U_4	3	3	1	5	4

On veut estimer $r_{1,5}$.

Similarité cosinus (définition)

Pour deux utilisateurs u et v et l'ensemble C des items co-notés, la similarité cosinus (sur vecteurs de notes brutes) est :

$$\text{sim}_{\cos}(u, v) = \frac{\sum_{i \in C} r_{u,i} r_{v,i}}{\sqrt{\sum_{i \in C} r_{u,i}^2} \sqrt{\sum_{i \in C} r_{v,i}^2}}.$$

Cette mesure vaut le cosinus de l'angle entre les deux vecteurs de notes restreints à C .

La prédiction que nous utiliserons est la moyenne pondérée directe (non centrée) :

$$\hat{r}_{1,5} = \frac{\sum_{v \in N} \text{sim}_{\cos}(1, v) r_{v,5}}{\sum_{v \in N} |\text{sim}_{\cos}(1, v)|},$$

où N est l'ensemble des utilisateurs ayant noté I_5 (ici U_2, U_3, U_4).

Calculs — similarités cosinus sur I_1, I_2, I_3, I_4

Vecteurs (sur I_1, I_2, I_3, I_4) :

$$\begin{aligned}\mathbf{r}_1 &= [5, 3, 4, 4], \\ \mathbf{r}_2 &= [3, 1, 2, 3], \\ \mathbf{r}_3 &= [4, 3, 4, 3], \\ \mathbf{r}_4 &= [3, 3, 1, 5].\end{aligned}$$

Nous calculons pour chaque $v \in \{2, 3, 4\}$ le produit scalaire, les normes, puis la similarité.

Produit scalaire et normes

Entre U_1 et U_2 .

$$\begin{aligned}\mathbf{r}_1 \cdot \mathbf{r}_2 &= 5 \cdot 3 + 3 \cdot 1 + 4 \cdot 2 + 4 \cdot 3 \\ &= 15 + 3 + 8 + 12 = 38. \\ \|\mathbf{r}_1\| &= \sqrt{5^2 + 3^2 + 4^2 + 4^2} = \sqrt{25 + 9 + 16 + 16} = \sqrt{66}. \\ \|\mathbf{r}_2\| &= \sqrt{3^2 + 1^2 + 2^2 + 3^2} = \sqrt{9 + 1 + 4 + 9} = \sqrt{23}.\end{aligned}$$

Produit des normes :

$$\|\mathbf{r}_1\| \|\mathbf{r}_2\| = \sqrt{66} \sqrt{23} = \sqrt{66 \cdot 23} = \sqrt{1518} \approx 38.961519477556315.$$

Donc

$$\text{sim}_{\cos}(U_1, U_2) = \frac{38}{38.961519477556315} \approx 0.9753213044447562.$$

Entre U_1 et U_3 .

$$\begin{aligned}\mathbf{r}_1 \cdot \mathbf{r}_3 &= 5 \cdot 4 + 3 \cdot 3 + 4 \cdot 4 + 4 \cdot 3 \\ &= 20 + 9 + 16 + 12 = 57. \\ \|\mathbf{r}_3\| &= \sqrt{4^2 + 3^2 + 4^2 + 3^2} = \sqrt{16 + 9 + 16 + 9} = \sqrt{50}.\end{aligned}$$

Produit des normes :

$$\|\mathbf{r}_1\| \|\mathbf{r}_3\| = \sqrt{66} \sqrt{50} = \sqrt{66 \cdot 50} = \sqrt{3300} \approx 57.44562646538029.$$

Donc

$$\text{sim}_{\cos}(U_1, U_3) = \frac{57}{57.44562646538029} \approx 0.9922426389474776.$$

Entre U_1 et U_4 .

$$\begin{aligned}\mathbf{r}_1 \cdot \mathbf{r}_4 &= 5 \cdot 3 + 3 \cdot 3 + 4 \cdot 1 + 4 \cdot 5 \\ &= 15 + 9 + 4 + 20 = 48. \\ \|\mathbf{r}_4\| &= \sqrt{3^2 + 3^2 + 1^2 + 5^2} = \sqrt{9 + 9 + 1 + 25} = \sqrt{44}.\end{aligned}$$

Produit des normes :

$$\|\mathbf{r}_1\| \|\mathbf{r}_4\| = \sqrt{66} \sqrt{44} = \sqrt{66 \cdot 44} = \sqrt{2904} \approx 53.88877434122992.$$

Donc

$$\text{sim}_{\cos}(U_1, U_4) = \frac{48}{53.88877434122992} \approx 0.8907235428302466.$$

Récapitulatif des similarités :

$$\begin{aligned}\text{sim}_{\cos}(U_1, U_2) &\approx 0.9753213044, \\ \text{sim}_{\cos}(U_1, U_3) &\approx 0.9922426389, \\ \text{sim}_{\cos}(U_1, U_4) &\approx 0.8907235428.\end{aligned}$$

Prédiction de $r_{1,5}$ (moyenne pondérée non centrée)

Les notes observées sur I_5 sont :

$$r_{2,5} = 3, \quad r_{3,5} = 5, \quad r_{4,5} = 4.$$

Calcul du numérateur pondéré :

$$\begin{aligned} \text{num} &= 0.9753213044447562 \times 3 + 0.9922426389474776 \times 5 + 0.8907235428302466 \times 4 \\ &\approx 2.9259639133342686 + 4.961213194737388 + 3.5628941713209864 \\ &\approx 11.450071279392643. \end{aligned}$$

Dénominateur (somme des valeurs absolues des similarités) :

$$\begin{aligned} \text{den} &= 0.9753213044447562 + 0.9922426389474776 + 0.8907235428302466 \\ &\approx 2.8582874862224803. \end{aligned}$$

Ainsi la prédiction :

$$\hat{r}_{1,5} = \frac{\text{num}}{\text{den}} \approx \frac{11.450071279392643}{2.8582874862224803} \approx 4.005920095366293.$$

On peut arrondir à 4.01 (ou à 4.0 si l'on préfère une seule décimale). Interprétation : avec la similarité cosinus calculée sur les notes brutes, la note prédite pour U_1 sur I_5 est très proche de 4.

Remarques

- Si l'on avait utilisé **cosinus sur vecteurs centrés** (i.e. appliquer la similarité cosinus après avoir soustrait la moyenne de chaque utilisateur), on aurait obtenu exactement les mêmes valeurs que la corrélation de Pearson calculée précédemment (puisque Pearson est le cosinus entre vecteurs centrés).
- Ici nous avons choisi *cosinus sur vecteurs bruts* et une prédiction non centrée (moyenne pondérée des notes). Cela donne une prédiction légèrement différente de la variante centrée (Pearson + correction par moyenne) ; la décision de centrer ou non dépend du modèle que vous voulez (corriger l'effet d'échelle des utilisateurs ou non).