

Exercice pratique : KNN (classification de fruit)

Séance 3 – Master Génie Informatique

10 novembre 2025

Contexte et objectif

- Objectif : prédire si un fruit est une **Pomme** ou une **Orange**.
- Caractéristiques disponibles : **Poids (g)** et **Diamètre (cm)**.
- Méthode : k-NN avec $k = 3$, distance euclidienne.

Jeu de données d'entraînement

Fruit	Poids (g)	Diamètre (cm)	Classe
A	120	7.0	Pomme
B	130	6.5	Pomme
C	150	8.0	Orange
D	170	8.2	Orange
E	160	7.8	Orange

Fruit à classifier F : **Poids = 140 g, Diamètre = 7.5 cm.**

Formule de la distance euclidienne

Pour deux points $x = (p_x, d_x)$ et $y = (p_y, d_y)$:

$$d(x, y) = \sqrt{(p_x - p_y)^2 + (d_x - d_y)^2}.$$

Nous allons calculer $d(F, A)$, $d(F, B)$, etc.

Calculs (1) – distances

$$d(F, A) = \sqrt{(140 - 120)^2 + (7.5 - 7.0)^2} = \sqrt{400 + 0.25} \approx 20.00$$

$$d(F, B) = \sqrt{(140 - 130)^2 + (7.5 - 6.5)^2} = \sqrt{100 + 1} \approx 10.05$$

$$d(F, C) = \sqrt{(140 - 150)^2 + (7.5 - 8.0)^2} = \sqrt{100 + 0.25} \approx 10.01$$

Calculs (2) – distances (suite)

$$d(F, D) = \sqrt{(140 - 170)^2 + (7.5 - 8.2)^2} = \sqrt{900 + 0.49} \approx 30.01$$

$$d(F, E) = \sqrt{(140 - 160)^2 + (7.5 - 7.8)^2} = \sqrt{400 + 0.09} \approx 20.00$$

Tri et sélection des 3 plus proches voisins ($k = 3$)

Fruit	Distance	Classe
C	≈ 10.01	Orange
B	≈ 10.05	Pomme
A	≈ 20.00	Pomme
E	≈ 20.00	Orange
D	≈ 30.01	Orange

Les 3 voisins les plus proches sont : **C (Orange)**, **B (Pomme)**, **A (Pomme)**.

Vote majoritaire et décision

- Votes parmi les 3 voisins : Pomme = 2, Orange = 1.
- Décision KNN ($k = 3$) : **Pomme**.

Remarques pédagogiques :

- On peut illustrer l'effet de k en affichant les frontières de décision pour $k = 1, 3, 5$.
- Montrer l'effet d'une pondération inverse à la distance (voisin plus proche influence plus).
- Normalisation : poids en grammes et diamètre en cm ont échelles différentes; on peut normaliser si nécessaire.

- ① Refaire l'exercice avec distance Manhattan et comparer le résultat.
- ② Utiliser $k = 1$ et $k = 5$ et discuter du sur-apprentissage / sous-apprentissage.
- ③ Appliquer une version pondérée : $w_i = 1/distance$ et recalculer la classe.
- ④ Ajouter une troisième caractéristique (couleur comme variable catégorielle) et discuter du traitement.