

Introduction au Machine Learning

Cours de Master 2 Génie Logiciel: — Apprentissage
Automatique

Université Assane Seck de Ziguinchor

15 octobre 2025

Plan du chapitre

Définitions et principes fondamentaux

- Définition

- Éléments constitutifs et formalisation

- ML et IA

Types de problèmes en machine learning

- Apprentissage supervisé

Apprentissage non supervisé

- Apprentissage semi supervisé

- Apprentissage par renforcement

PROCESSUS GÉNÉRAL DU MACHINE LEARNING

- Ressources pratiques

Qu'est-ce que le Machine Learning ?

- ▶ Le **Machine Learning (ML)** ou apprentissage automatique est une branche de l'intelligence artificielle.
- ▶ Il permet à une machine **d'apprendre à partir de données**, sans être explicitement programmée pour chaque tâche.
- ▶ Définition : « L'apprentissage est une modification d'un comportement sur la base d'une expérience » (Benureau, 2015).
- ▶ En ML : les données et les résultats sont utilisés pour générer les règles (le modèle).

Qu'est-ce que le Machine Learning ?

- ▶ Le **Machine Learning (ML)** ou apprentissage automatique est une branche de l'intelligence artificielle.
- ▶ Il permet à une machine **d'apprendre à partir de données**, sans être explicitement programmée pour chaque tâche.
- ▶ Définition : « L'apprentissage est une modification d'un comportement sur la base d'une expérience » (Benureau, 2015).
- ▶ En ML : les données et les résultats sont utilisés pour générer les règles (le modèle).

Comparaison :

- ▶ **Programme classique** : Données + Instructions → Résultat
- ▶ **Machine Learning** : Données + Résultat → Instructions (modèle)

Pourquoi utiliser le Machine Learning ?

- ▶ Pour résoudre des problèmes :
 - ▶ **Non formalisables facilement** (vision par ordinateur, traitement du langage, etc.)
 - ▶ **Trop coûteux** en ressources via des méthodes classiques
 - ▶ **Mal connus** mais pour lesquels des données sont disponibles
- ▶ **Exemple** : prédire les prochains achats d'un client à partir de son historique (exige apprentissage à partir de patterns)

Pourquoi utiliser le Machine Learning ?

- ▶ Pour résoudre des problèmes :
 - ▶ **Non formalisables facilement** (vision par ordinateur, traitement du langage, etc.)
 - ▶ **Trop coûteux** en ressources via des méthodes classiques
 - ▶ **Mal connus** mais pour lesquels des données sont disponibles
- ▶ **Exemple** : prédire les prochains achats d'un client à partir de son historique (exige apprentissage à partir de patterns)

Utilisations fréquentes :

- ▶ Recommandation (Netflix, Amazon)
- ▶ Détection de fraude (banques)
- ▶ Diagnostic médical (images, génomique)
- ▶ Modélisation scientifique (climat, astrophysique)

Les ingrédients du ML

- ▶ **Les données** : source d'apprentissage. Qualité essentielle !
- ▶ **L'algorithme d'apprentissage** : procédure mathématique transformant des données d'entrée en modèle.
- ▶ **Le modèle** : résultat de l'algorithme, utilisé ensuite comme un programme classique.

Les ingrédients du ML

- ▶ **Les données** : source d'apprentissage. Qualité essentielle !
- ▶ **L'algorithme d'apprentissage** : procédure mathématique transformant des données d'entrée en modèle.
- ▶ **Le modèle** : résultat de l'algorithme, utilisé ensuite comme un programme classique.

Garbage In, Garbage Out : un bon algorithme ne peut rien apprendre à partir de mauvaises données !

Les ingrédients du ML

- ▶ **Les données** : source d'apprentissage. Qualité essentielle !
- ▶ **L'algorithme d'apprentissage** : procédure mathématique transformant des données d'entrée en modèle.
- ▶ **Le modèle** : résultat de l'algorithme, utilisé ensuite comme un programme classique.

Garbage In, Garbage Out : un bon algorithme ne peut rien apprendre à partir de mauvaises données !

Processus global

Préparation des données → Entraînement du modèle → Évaluation
→ Utilisation

Modélisation, Optimisation et Intelligence

- ▶ Objectif : **minimiser une erreur** (fonction de coût) ou **maximiser une performance**
- ▶ Apprentissage = problème d'**optimisation** mathématique
- ▶ Algorithmes différents selon le type de tâche : classification, régression, clustering, etc.

Modélisation, Optimisation et Intelligence

- ▶ Objectif : **minimiser une erreur** (fonction de coût) ou **maximiser une performance**
- ▶ Apprentissage = problème d'**optimisation** mathématique
- ▶ Algorithmes différents selon le type de tâche : classification, régression, clustering, etc.

Exemples :

- ▶ Classer des clients par profils d'achat
- ▶ Prédire la trajectoire d'un véhicule
- ▶ Détecter des anomalies médicales ou financières

Modélisation, Optimisation et Intelligence

- ▶ Objectif : **minimiser une erreur** (fonction de coût) ou **maximiser une performance**
- ▶ Apprentissage = problème d'**optimisation** mathématique
- ▶ Algorithmes différents selon le type de tâche : classification, régression, clustering, etc.

Exemples :

- ▶ Classer des clients par profils d'achat
- ▶ Prédire la trajectoire d'un véhicule
- ▶ Détecter des anomalies médicales ou financières

Double fondation du ML :

- ▶ **Mathématiques (statistiques)** : modélisation, inférence
- ▶ **Informatique** : représentation, calcul, implémentation

ML et Intelligence Artificielle

- ▶ Le Machine Learning est une **sous-branche de l'intelligence artificielle**
- ▶ L'IA vise à créer des machines capables d'**adopter un comportement intelligent**
- ▶ L'apprentissage est une composante clé de cette intelligence

ML et Intelligence Artificielle

- ▶ Le Machine Learning est une **sous-branche de l'intelligence artificielle**
- ▶ L'IA vise à créer des machines capables d'**adopter un comportement intelligent**
- ▶ L'apprentissage est une composante clé de cette intelligence

Disciplines associées :

- ▶ Sciences cognitives, neurobiologie, logique, ingénierie, électronique...
- ▶ L'IA combine données, modèles, raisonnement et adaptation

Types de problèmes en machine learning

Le machine learning est un champ assez vaste, et nous dressons dans cette section une liste des plus grandes classes de problèmes auxquels il s'intéresse.

- ▶ Apprentissage supervisé
- ▶ Apprentissage non supervisé
- ▶ Apprentissage semi supervisé
- ▶ Apprentissage par renforcement

Apprentissage supervisé

définition et objectifs

L'apprentissage supervisé est peut-être le type de problèmes de machine learning le plus facile à appréhender : son but est d'apprendre à faire des prédictions, à partir d'une liste d'exemples étiquetés, c'est-à-dire accompagnés de la valeur à prédire (voir figure 1.1). Les étiquettes servent de « professeur » et supervisent l'apprentissage de l'algorithme.

Formalisation :

Déterminer une fonction $f : \mathcal{X} \rightarrow \mathcal{Y}$ approchant une fonction inconnue $\varphi(x)$ telle que $y = \varphi(x) + \epsilon$ à partir d'exemples étiquetés.

But : apprendre f telle que $f(x) \approx \varphi(x)$ pour toute nouvelle entrée x .

Apprentissage supervisé




FIGURE 1.1 – Apprentissage supervisé.

Cas typique :

- ▶ Données d'entrée : $\mathcal{X} = \mathbb{R}^P$ (vecteurs de caractéristiques)
- ▶ Données de sortie $\mathcal{Y}$:
 - ▶ $\{0,1\}$ pour classification binaire
 - ▶ $\{1, \dots, C\}$ pour classification multi-classe
 - ▶ $\mathbb{R}$ pour la régression

Apprentissage supervisé

Classification binaire et multi-classe

Classification binaire ($\mathcal{Y} = \{0, 1\}$) :

- ▶ Prédire une étiquette binaire (ex : maladie présente / absente)
- ▶ **Exemples** : spam detection, fraude bancaire, reconnaissance d'objet spécifique

Classification multi-classe ($\mathcal{Y} = \{1, \dots, C\}$) :

- ▶ Prédire une catégorie parmi plusieurs possibles
- ▶ **Exemples** :
 - ▶ Langue d'un texte
 - ▶ Chiffre manuscrit (MNIST)
 - ▶ Expression faciale (joie, colère, tristesse)

Apprentissage supervisé

Régression : prédire des valeurs continues

Definition (Régression)

Un problème d'apprentissage supervisé dans lequel l'espace des étiquettes est $\mathcal{Y} = \mathbb{R}$ est appelé un problème de régression.

Le but est de prédire une valeur réelle à partir d'un vecteur de caractéristiques.

Exemples :

- ▶ Prédire le nombre de clics sur un lien publicitaire
- ▶ Prédire la température demain à midi
- ▶ Estimer le montant d'un panier client

Remarque : on peut combiner régression et classification pour des tâches plus complexes (ex : scoring + seuil).

Apprentissage supervisé

Régression structurée et remarques finales

Régression structurée : prédiction de sorties complexes (vecteurs, images, séquences)

► Exemples :

- Traduction automatique
 - Reconnaissance vocale / text-to-speech
 - Annotation d'image (bounding boxes)
- Moins abordée dans les cours classiques mais essentielle en NLP ou vision par ordinateur

À retenir :

- Les types de sortie définissent le type de problème (binaire, multi-classe, régression)
- Chaque type nécessite un traitement et des métriques spécifiques

Apprentissage non supervisé

Definition (Apprentissage non supervisé)

On appelle *apprentissage non supervisé* la branche du machine learning qui s'intéresse aux problèmes pouvant être formalisés de la façon suivante : étant données n observations $\{\tilde{x}_i\}_{i=1,\dots,n}$ décrites dans un espace $\mathcal{X}$, il s'agit d'apprendre une fonction sur $\mathcal{X}$ qui vérifie certaines propriétés.



FIGURE 1.2 – Apprentissage non supervisé.

Apprentissage non supervisé

Clustering ou partitionnement

Definition (Partitionnement)

On appelle *partitionnement* ou *clustering* un problème d'apprentissage non supervisé pouvant être formalisé comme la recherche d'une partition $\bigsqcup_{k=1}^K C_k$ des n observations $\{\tilde{x}_i\}_{i=1,\dots,n}$. Cette partition doit être pertinente au vu d'un ou plusieurs critères à préciser.




FIGURE 1.3 – Partitionnement des données, ou clustering.

Apprentissage non supervisé

Quelques exemples

- ▶ Applications :
 - ▶ Segmentation de marché (groupes de clients)
 - ▶ Organisation automatique de documents
 - ▶ Segmentation d'image ou de patients
 - ▶ Compression (groupement de pixels similaires)
- ▶ Méthodes classiques : K-means, DBSCAN, Hierarchical Clustering

Apprentissage non supervisé

Réduction de dimension

- ▶ Objectif : représenter les données dans un espace de plus petite dimension tout en conservant l'essentiel.
- ▶ **Définition** : recherche d'un espace Z de dimension plus faible que X et projection des données.
- ▶ Intérêts :
 - ▶ Simplification des modèles
 - ▶ Réduction du bruit et du temps de calcul
 - ▶ Visualisation des données




FIGURE 1.4 – Réduction de dimension.

- ▶ Exemple : PCA (analyse en composantes principales), t-SNE

Apprentissage non supervisé

Estimation de densité de probabilité

- ▶ Objectif : approximer la distribution sous-jacente des données (densité de probabilité)
- ▶ Hypothèse : les données sont issues d'un échantillon aléatoire
- ▶ Utilités : détection d'anomalies, génération de données (ex : GANs), compression
- ▶ Méthodes : estimation par noyaux, modèles de mélange gaussien (GMM)

Apprentissage semi-supervisé

Définition :

L'apprentissage semi-supervisé combine données étiquetées et non étiquetées pour entraîner un modèle.

Motivation :

- ▶ Réduire le besoin en étiquetage manuel coûteux ou chronophage.
- ▶ Exploiter de grands volumes de données non annotées.
- ▶ Limiter les biais induits par un étiquetage humain subjectif.

Exemple :

- ▶ Classification d'images : des millions d'images disponibles, mais peu sont étiquetées.
- ▶ Approches courantes : auto-labelling, propagation de labels, pseudo-étiquetage.

Remarque : Approche puissante mais avancée — non couverte en détail dans ce cours.

Apprentissage par renforcement

Définition :

Un agent apprend en interagissant avec un environnement. Il reçoit des **récompenses** positives ou négatives selon ses actions.

Objectif : Apprendre une **politique optimale** pour maximiser les récompenses cumulées.

Caractéristiques :

- ▶ Apprentissage séquentiel (les décisions influencent les futures observations).
- ▶ Récompenses différées : effet d'une action peut apparaître après plusieurs étapes.
- ▶ Exemple : apprendre à jouer au jeu de Go ou à piloter un robot.

Domaines d'application : Jeux, robotique, contrôle de drones, conduite autonome.

Note : Sujet très vaste traité en profondeur dans des cours spécialisés.

PROCESSUS GÉNÉRAL DU MACHINE LEARNING

- ▶ Collecte des données
- ▶ Séparation des données et choix du modèle
- ▶ Entraînement et évaluation du modèle
- ▶ Ajustement du modèle
- ▶ Prédiction et utilisation du modèle

Étape 1 : Collecte des données

- ▶ **Objectif** : Obtenir des données pertinentes pour répondre à une problématique concrète.
- ▶ **Sources possibles** : fichiers CSV, bases de données, API, capteurs IoT, données web.
- ▶ **Prétraitement nécessaire** :
 - ▶ Nettoyage (valeurs manquantes, doublons, anomalies)
 - ▶ Normalisation ou standardisation
 - ▶ Encodage des variables catégorielles
- ▶ *Exemple* : Collecter des dossiers médicaux pour prédire le risque de diabète.

Étape 2 : Séparation des données et choix du modèle

Séparation des données

- ▶ Entraînement (train) : 70–80 %
- ▶ Validation : 10–15 %
- ▶ Test : 10–15 %
- ▶ **But** : Éviter le surapprentissage et évaluer la généralisation.

Choix du modèle

- ▶ Dépend du type de problème : classification, régression, clustering...
- ▶ Modèles courants : arbres de décision, régressions, k-NN, SVM, réseaux de neurones.
- ▶ Prise en compte de la complexité et des ressources disponibles.

Étape 3 : Entraînement et évaluation du modèle

Entraînement du modèle

- ▶ Le modèle apprend les relations entre variables explicatives et variable cible.
- ▶ Utilise uniquement les données d'entraînement.
- ▶ Ajustement des poids (paramètres internes) pour minimiser une fonction de perte.

Évaluation des performances

- ▶ Utilise les données de validation.
- ▶ Mesure la précision, le rappel, la F-mesure, RMSE, etc.
- ▶ Permet de détecter le surapprentissage.

Étape 4 : Ajustement du modèle

- ▶ **Objectif** : Améliorer les performances sur les données de validation.
- ▶ Techniques courantes :
 - ▶ Recherche d'hyperparamètres (grid search, random search, Bayésien)
 - ▶ Régularisation (L1, L2)
 - ▶ Feature engineering (création de nouvelles variables)
- ▶ **Validation croisée** : méthode robuste pour évaluer les performances moyennes d'un modèle.
- ▶ *Résultat attendu* : modèle avec bon compromis biais/variance.

Étape 5 : Prédiction et utilisation du modèle

- ▶ **Prédiction** : Application du modèle sur de nouvelles données non vues.
- ▶ **Utilisation concrète** :
 - ▶ Détection automatique d'emails frauduleux
 - ▶ Recommandation de produits personnalisés
 - ▶ Diagnostic médical assisté par l'IA
- ▶ **Mise en production** :
 - ▶ Intégration dans une application ou un service
 - ▶ Surveillance des performances en conditions réelles
 - ▶ Réentraînement régulier si nécessaire (data drift)



Collecte des données

Acquisition de données pertinentes



Séparation des données

Train / validation / test



Choix & entraînement du modèle

Régression, classification, etc.



Évaluation des performances

Cross-validation, métriques



Ajustement du modèle

Optimisation, tuning

Ressources pratiques : Outils et bibliothèques

Implémentations open source majeures :

- ▶ **Scikit-learn (Python)** : Bibliothèque très utilisée, soutenue par Inria et Télécom ParisTech. <http://scikit-learn.org/>
- ▶ **R** : De nombreux packages ML disponibles sur CRAN <http://cran.r-project.org/web/views/MachineLearning.html>
- ▶ **Weka (Java)** : Suite d'outils ML avec interface graphique. <https://www.cs.waikato.ac.nz/ml/weka/>
- ▶ **Shogun** : Compatible avec Python, R, Octave, C. <http://www.shogun-toolbox.org/>
- ▶ **TensorFlow** : Apprentissage profond, calcul distribué. <https://www.tensorflow.org>

Remarque : Tous ces outils permettent de tester rapidement des modèles, et sont bien documentés.

Ressources pratiques : Jeux de données

Bases de données disponibles en accès libre :

- ▶ **UCI ML Repository** : Référentiel académique historique
<http://www.ics.uci.edu/~mllearn/MLRepository.html>
- ▶ **KDNuggets** : Nombreux jeux de données thématiques
<http://www.kdnuggets.com/datasets/index.html>
- ▶ **Kaggle** : Plateforme de compétitions et partage de datasets
<https://www.kaggle.com/>

Utilisation pédagogique :

- ▶ S'entraîner à explorer, visualiser et modéliser.
- ▶ Tester et comparer les performances de différents algorithmes.

Conseil : Choisir un jeu de données adapté au type de tâche (classification, régression, etc.).