

Machine Learning

Scéance 3 : Régression Linéaire

Université Assane Seck de Ziguinchor
Professeur : Dr Ousseynou Mbaye

Année universitaire 2024–2025

Plan du cours

- 1 Objectif général
- 2 Objectifs spécifiques
- 3 Régression Linéaire Simple
- 4 Régression Linéaire Multiple
- 5 Conclusion

Objectifs d'apprentissage

Objectif général

Sélectionner, appliquer et évaluer un modèle de prédiction (régression).

Objectifs spécifiques

- ➊ Appliquer et évaluer une régression linéaire simple
- ➋ Appliquer et évaluer une régression linéaire multiple

Définition

La régression linéaire simple étudie la relation entre une variable dépendante Y et une variable indépendante X :

$$Y = \beta_0 + \beta_1 X + \epsilon$$

- β_0 : ordonnée à l'origine
- β_1 : coefficient de régression
- ϵ : terme d'erreur

Exemple concret : Ventes vs Budget Publicitaire

Données :

Budget (X , k€)	Ventes (Y , milliers d'unités)
2	20
3	25
5	35
7	45
8	50

Objectif : Estimer la relation entre budget et ventes et prédire les ventes futures.

Coefficient de corrélation linéaire r

Définition

$$r = \frac{\text{cov}(x, y)}{\sigma_x \sigma_y}$$

Interprétation

- $r \rightarrow 1$: forte corrélation positive
- $r \rightarrow -1$: forte corrélation négative
- $r \rightarrow 0$: faible corrélation

Composantes du calcul

- Covariance : $\text{cov}(x, y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$
- Écart-type : $\sigma_x = \sqrt{\sigma_x^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$

Exemple : Prédiction du prix d'une maison

Données d'exemple

Superficie (m ²)	Prix (millions CFA)
50	15
70	22
90	28
110	35
130	42

- Objectif : Prédire le prix d'une maison en fonction de sa superficie
- Approche : Régression linéaire simple
- Données : 5 observations de maisons

Modèle de régression linéaire

$$y = \theta_0 + \theta_1 x + \epsilon$$

Variables et paramètres

- y = prix de la maison (variable dépendante)
- x = superficie (variable indépendante)
- θ_0 = ordonnée à l'origine (prix de base)
- θ_1 = pente (augmentation du prix par m²)
- ϵ = terme d'erreur

Méthode de calcul des paramètres

Formules analytiques

$$\theta_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$
$$\theta_0 = \bar{y} - \theta_1 \bar{x}$$

Calcul des moyennes

$$\bar{x} = \frac{50 + 70 + 90 + 110 + 130}{5} = 90 \text{ m}^2$$

$$\bar{y} = \frac{15 + 22 + 28 + 35 + 42}{5} = 28.4 \text{ millions CFA}$$

Résultats et interprétation

Tableau des écarts

x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$	$(x_i - \bar{x})^2$
50	15	-40	-13.4	536	1600
70	22	-20	-6.4	128	400
90	28	0	-0.4	0	0
110	35	20	6.6	132	400
130	42	40	13.6	544	1600

Calcul final

$$\theta_1 = \frac{1340}{4000} = 0.335 \text{ millions CFA/m}^2$$

$$\theta_0 = 28.4 - 0.335 \times 90 = -1.75 \text{ millions CFA}$$

Modèle final

$$y = -1.75 + 0.335x$$

Interprétation du modèle

Modèle obtenu

$$\text{Prix} = -1.75 + 0.335 \times \text{Superficie}$$

- **Pente** ($\theta_1 = 0.335$) : Chaque m^2 supplémentaire augmente le prix de 0.335 millions CFA (335 000 CFA)
- **Ordonnée à l'origine** ($\theta_0 = -1.75$) :
 - Valeur négative théorique
 - Indique que le modèle n'est valable que pour des superficies suffisamment grandes
 - Pour $x = 0$, le prix serait négatif (non réaliste)

Domaine de validité

Le modèle est pertinent pour des superficies supérieures à environ $5\text{-}6 \text{ m}^2$ (là où le prix devient positif)

Régression simple en Python

```
import numpy as np
from sklearn.linear_model import LinearRegression

X = np.array([50, 70, 90, 110, 130]).reshape(-1,1)
Y = np.array([15, 22, 328, 35, 42])

model = LinearRegression()
model.fit(X, Y)
Y_pred = model.predict(X)

print(model.intercept_, model.coef_[0])
```

Résultat : $\hat{\beta}_0 = -1,75$, $\hat{\beta}_1 = 0,335$

Définition La régression linéaire multiple inclut plusieurs variables indépendantes :

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \epsilon$$

Exemple : Prix des maisons

- Y = prix en milliers €
- X_1 = surface (m²)
- X_2 = nombre de chambres
- X_3 = âge de la maison

Estimation des coefficients par moindres carrés

du problème d'optimisation Les coefficients θ sont obtenus en minimisant la somme des moindres carrés :

$$\hat{\theta} = \arg \min_{\theta \in \mathbb{R}^{p+1}} \sum_{i=1}^n \left(y_i - \theta_0 - \sum_{j=1}^p \theta_j x_{ij} \right)^2$$

matricielle

Ce problème d'optimisation admet une solution analytique sous forme matricielle :

Soit $X \in \mathbb{R}^{n \times (p+1)}$ la matrice des variables explicatives (avec colonne de 1 pour l'intercept) et $y \in \mathbb{R}^n$ le vecteur des observations, alors :

$$\hat{\theta} = (X^T X)^{-1} X^T y$$

Conditions d'application

- $X^T X$ doit être inversible (colonnes linéairement indépendantes)
- Solution optimale unique sous ces conditions
- Méthode des moindres carrés ordinaires (MCO)

Exemple : Prédiction du prix d'une maison

Données d'exemple

Superficie (m ²)	Chambres	Âge (années)	Prix (millions CFA)
80	2	5	25
100	3	10	30
120	3	2	38
150	4	15	42
90	2	8	28
110	3	12	32

- Objectif : Prédire le prix d'une maison avec **trois variables explicatives**
- Variables :
 - Superficie (x_1)
 - Nombre de chambres (x_2)
 - Âge de la maison (x_3)
- Variable à expliquer : Prix (y)

Formulation du modèle et approche matricielle

Modèle de régression multiple

$$y = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3 + \epsilon$$

Formulation matricielle

$$\mathbf{y} = \mathbf{X}\boldsymbol{\theta} + \boldsymbol{\epsilon}$$

$$\mathbf{X} = \begin{pmatrix} 1 & 80 & 2 & 5 \\ 1 & 100 & 3 & 10 \\ 1 & 120 & 3 & 2 \\ 1 & 150 & 4 & 15 \\ 1 & 90 & 2 & 8 \\ 1 & 110 & 3 & 12 \end{pmatrix} \quad \mathbf{y} = \begin{pmatrix} 25 \\ 30 \\ 38 \\ 42 \\ 28 \\ 32 \end{pmatrix}$$

Équation normale

$$\mathbf{X}^\top \mathbf{X} \boldsymbol{\theta} = \mathbf{X}^\top \mathbf{y}$$

Calculs intermédiaires

$$\mathbf{X}^\top \mathbf{X} = \begin{pmatrix} 6 & 650 & 17 & 52 \\ 650 & 72500 & 1870 & 5920 \\ 17 & 1870 & 51 & 158 \\ 52 & 5920 & 158 & 546 \end{pmatrix} \quad \mathbf{X}^\top \mathbf{y} = \begin{pmatrix} 195 \\ 21670 \\ 560 \\ 1736 \end{pmatrix}$$

Solution du système

$$\theta_0 = -2.85 \text{ millions CFA}$$

$$\theta_1 = 0.28 \text{ millions CFA/m}^2$$

$$\theta_2 = 3.45 \text{ millions CFA/chambre}$$

$$\theta_3 = -0.15 \text{ millions CFA/année}$$

Interprétation des Coefficients du modèle de régression multiple

$\theta_0 = -2.85$ millions CFA (constante)

$\theta_1 = 0.28$ millions CFA/m² (effet de la superficie)

$\theta_2 = 3.45$ millions CFA/chambre (effet du nombre de chambres)

$\theta_3 = -0.15$ millions CFA/année (effet de l'âge, négatif car plus vieux = moins)

Application du modèle

Modèle final

$$y = -2.85 + 0.28x_1 + 3.45x_2 - 0.15x_3$$

Exemple de prédiction

Maison : 95m², 3 chambres, 7 ans

$$\begin{aligned} y &= -2.85 + 0.28(95) + 3.45(3) - 0.15(7) \\ &= -2.85 + 26.6 + 10.35 - 1.05 \\ &= 33.05 \text{ millions CFA} \end{aligned}$$

Régression multiple en Python

```
import pandas as pd
from sklearn.linear_model import LinearRegression

data = {'Surface': [50, 60, 70, 80, 90],
        'Chambres': [2, 2, 3, 3, 4],
        'Age': [10, 5, 20, 15, 5],
        'Prix': [150, 180, 200, 220, 260]}
df = pd.DataFrame(data)

X = df[['Surface', 'Chambres', 'Age']]
Y = df['Prix']
model = LinearRegression()
model.fit(X, Y)
Y_pred = model.predict(X)
print(model.intercept_)
print(model.coef_)
```

Décomposition de la variance

$$\underbrace{\sum_{i=1}^n (y_i - \bar{y})^2}_{SCT} = \underbrace{\sum_{i=1}^n (y_i - \hat{y}_i)^2}_{SCR} + \underbrace{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}_{SCE}$$

- **SCT** : Somme des carrés totaux
- **SCE** : Somme des carrés expliqués par le modèle
- **SCR** : Somme des carrés résiduels

Coefficient de détermination R^2

$$R^2 = \frac{SCE}{SCT} = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{SCR}{SCT}$$

- $R^2 \rightarrow 1$: le modèle est de bonne qualité
- $R^2 \rightarrow 0$: le modèle n'est pas bon

Autres métriques de validation

- **MSE** (Mean Squared Error) :

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- **RMSE** (Root Mean Squared Error) :

$$RMSE = \sqrt{MSE}$$

- **Mean Absolute Error (MAE)**

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- **Interprétation** : Erreur moyenne absolue
- **Avantage** : Facile à interpréter, même unité que la variable cible
- **Inconvénient** : Non différentiable en zéro
- **Sensibilité** : Moins sensible aux outliers que MSE

Mean Squared Error (MSE)

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- **Interprétation** : Erreur quadratique moyenne
- **Avantage** : Différentiable, propriétés mathématiques intéressantes
- **Inconvénient** : Sensible aux valeurs extrêmes
- **Unité** : Carré de l'unité de la variable cible

Comparaison des métriques d'erreur

Root Mean Squared Error (RMSE)

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- **Interprétation** : Racine de l'erreur quadratique moyenne
- **Avantage** : Même unité que la variable cible
- **Propriété** : Donne plus de poids aux grandes erreurs
- **Utilisation** : Standard dans de nombreux domaines

Relations importantes

$$RMSE \geq MAE \quad (\text{inégalité de Jensen})$$

L'écart entre RMSE et MAE indique la variance des erreurs.

Formulation générale

Extension de la régression linéaire avec relations non-linéaires :

$$f(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \dots + \theta_d x^d$$

- Degré d du polynôme à choisir
- Capture des courbures dans les données
- Plus flexible que le modèle linéaire simple

Matrice des caractéristiques polynomiales :

$$X_{\text{poly}} = \begin{pmatrix} 1 & x_1 & x_1^2 & \dots & x_1^d \\ 1 & x_2 & x_2^2 & \dots & x_2^d \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \dots & x_n^d \end{pmatrix}$$

$$\hat{\theta} = \arg \min_{\theta \in \mathbb{R}^{d+1}} \sum_{i=1}^n \left(y_i - \theta_0 - \theta_1 x_i - \dots - \theta_d x_i^d \right)^2$$

$$\hat{\theta} = (X_{\text{poly}}^\top X_{\text{poly}})^{-1} X_{\text{poly}}^\top y$$

- Même principe que la régression linéaire
- Matrice X_{poly} à la place de X
- Risque de sur-apprentissage si degré trop élevé

Attention au sur-apprentissage

- Validation croisée pour choisir le degré optimal
- Régularisation possible (Ridge, Lasso)

Contexte

Utilisée lorsque la variable cible y est binaire ($y \in \{0, 1\}$)

Fonction logistique

$$P(y = 1|x) = \sigma(z) = \frac{1}{1 + e^{-z}}, \quad z = \theta_0 + \sum_{j=1}^p \theta_j x_j$$

- $\sigma(z)$: fonction sigmoïde
- Sortie entre 0 et 1 (probabilité)
- z : combinaison linéaire des caractéristiques

Fonction de décision

$$f(x) = \frac{1}{1 + e^{-(\theta_0 + \sum_{j=1}^p \theta_j x_j)}}$$

Maximum de vraisemblance Log-vraisemblance à maximiser :

$$\log L(\theta) = \sum_{i=1}^n [y_i \log(\sigma(z_i)) + (1 - y_i) \log(1 - \sigma(z_i))]$$

- Pas de solution analytique fermée
- Optimisation numérique (descente de gradient)

Interprétation des coefficients

$$\log \left(\frac{P(y = 1|x)}{P(y = 0|x)} \right) = \theta_0 + \sum_{j=1}^p \theta_j x_j$$

- θ_j : effet sur le log-odds
- e^{θ_j} : facteur multiplicatif des cotes

Application : Prix des Logements

Contexte

- Prédire le prix des maisons
- Caractéristiques : superficie, chambres, année, distance commodités...

Régression Linéaire Multiple

$$y = \theta_0 + \theta_1(\text{superficie}) + \theta_2(\text{chambres}) + \theta_3(\text{année}) + \epsilon$$

- Interprétation directe des coefficients
- Simplicité et transparence

Polynomiale

$$y = \theta_0 + \theta_1(\text{superficie}) + \theta_2(\text{superficie}^2) + \dots + \epsilon$$

- Capture les non-linéarités
- Rendements décroissants/croissants

Régression Logistique Immobilière

$$P(\text{prix} > 5M|x) = \frac{1}{1 + e^{-(\theta_0 + \theta_1(\text{superficie}) + \theta_2(\text{chambres}) + \dots)}}$$

- Prédire la probabilité de dépasser un seuil
- Utile pour la fixation des prix
- Analyse de la demande du marché

Choix du modèle

- **Linéaire** : Simplicité, interprétabilité
- **Polynomial** : Relations complexes, flexibilité
- **Logistique** : Probabilités, classification

Conclusion Ces méthodes fournissent une boîte à outils complète pour l'analyse immobilière, permettant des décisions stratégiques éclairées.

- La régression linéaire permet d'analyser et de prédire des relations linéaires.
- Les modèles simples et multiples sont facilement implémentables avec Python.
- L'évaluation du modèle se fait avec RMSE et R^2 .
- Les interactions entre variables permettent de modéliser des effets combinés.